

**TRƯỜNG ĐẠI HỌC BÁCH KHOA  
ĐẠI HỌC QUỐC GIA THÀNH PHỐ  
HỒ CHÍ MINH**

**KHOA KHOA HỌC ỨNG DỤNG**



**BÁO CÁO BÀI TẬP LỚN  
XÁC SUẤT VÀ THỐNG KÊ  
ĐỀ TÀI: PHÂN TÍCH YẾU TỐ  
ẢNH HƯỞNG ĐẾN NGUY CƠ BÉO PHÌ**

**Lớp: L19 - Nhóm: 10**

**Giảng viên hướng dẫn: Nguyễn Thị Kiều Ân**

| STT | Thành viên nhóm     | MSSV    | Tham gia |
|-----|---------------------|---------|----------|
| 1   | Nguyễn Ngọc Ánh     | 2410169 | Tham gia |
| 2   | Võ Quốc Đại         | 2410649 | Tham gia |
| 3   | Lê Nguyễn Trang Nhi | 2412501 | Tham gia |
| 4   | Nguyễn Ngọc Nhi     | 2412506 | Tham gia |
| 5   | Huỳnh Thiên Như     | 2412537 | Tham gia |

TP. Hồ Chí Minh, tháng 11/2025



# NHẬN XÉT CỦA GIẢNG VIÊN HƯỚNG DẪN

## Mục lục

|             |                                                                             |           |
|-------------|-----------------------------------------------------------------------------|-----------|
| <b>I.</b>   | <b>Tổng quan dữ liệu</b>                                                    | <b>3</b>  |
| <b>II.</b>  | <b>Kiến thức nền</b>                                                        | <b>4</b>  |
| 1.          | Các đặc trưng của tổng thể và mẫu . . . . .                                 | 4         |
| 2.          | Kiểm định giả thiết thống kê . . . . .                                      | 5         |
| 3.          | Phân tích phương sai . . . . .                                              | 6         |
| 3.1         | Giả thiết của bài toán ANOVA 1 yếu tố: . . . . .                            | 6         |
| 3.2         | Các bước thực hiện bài toán: . . . . .                                      | 6         |
| 4.          | Hồi quy Logistic có thứ tự (ordinal logistic) . . . . .                     | 9         |
| 4.1         | Khái niệm . . . . .                                                         | 9         |
| 4.2         | Giả định tỉ lệ chênh lệch tích lũy (Proportional Odds Assumption) . . . . . | 10        |
| 4.3         | Diễn giải hệ số (Odds Ratio - OR) . . . . .                                 | 10        |
| 5.          | Bản đồ nhiệt (Heatmap) . . . . .                                            | 11        |
| 5.1         | Màu sắc trong bản đồ nhiệt . . . . .                                        | 11        |
| 5.2         | Đồ thị tương quan (Correlogram) . . . . .                                   | 13        |
| <b>III.</b> | <b>Tiền xử lý dữ liệu</b>                                                   | <b>14</b> |
| 1.          | Đọc và Kiểm tra Dữ liệu . . . . .                                           | 14        |
| 2.          | Xử lý và chuyển đổi kiểu dữ liệu . . . . .                                  | 15        |
| 3.          | Xử lý biến và tạo chỉ số BMI . . . . .                                      | 15        |
| 4.          | Xử lý giá trị ngoại lai (Outlier) . . . . .                                 | 16        |
| <b>IV.</b>  | <b>Thống kê mô tả</b>                                                       | <b>19</b> |
| 1.          | Tính toán các giá trị thống kê mô tả . . . . .                              | 19        |
| 2.          | Sử dụng đồ thị để mô tả dữ liệu . . . . .                                   | 21        |
| <b>V.</b>   | <b>Thống kê suy diễn</b>                                                    | <b>33</b> |
| 1.          | Phân tích phương sai một nhân tố . . . . .                                  | 33        |
| 2.          | Hồi quy Logistic Thứ bậc (Ordinal Logistic Regression) . . . . .            | 39        |
| <b>VI.</b>  | <b>Thảo luận và mở rộng</b>                                                 | <b>56</b> |
| 1.          | Thảo luận . . . . .                                                         | 56        |
| 2.          | Mở rộng . . . . .                                                           | 56        |

## I Tổng quan dữ liệu

Tập dữ liệu Obesity\_Levels\_Estimation.csv gồm đặc điểm nhân khẩu học, yếu tố gia đình, thói quen ăn uống, tình trạng thể chất của các cá nhân từ Mexico, Peru và Colombia nhằm dự đoán Mức độ béo phì. Dữ liệu gồm 17 biến và 2.111 quan sát. Biến mục tiêu là NObeyesdad (Mức độ béo phì) có 7 cấp độ: Thiếu cân; Cân nặng bình thường; Thừa cân cấp độ I; Thừa cân cấp độ II; Béo phì loại I; Béo phì loại II và Béo phì loại III.

Cách thu thập: 77% dữ liệu được tổng hợp (synthetic) bằng công cụ WEKA và bộ lọc SMOTE, 23% dữ liệu còn lại được thu thập trực tiếp từ người dùng thông qua nền tảng web. Nguồn dữ liệu: [tại đây](#)

| STT | Tên biến                       | Loại biến  | Đơn vị   | Mô tả                                                                                                                                                                        |
|-----|--------------------------------|------------|----------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 1   | Gender                         | Phân loại  | -        | Cho biết giới tính của cá nhân. Với <i>Male</i> = đàn ông; <i>Female</i> = phụ nữ.                                                                                           |
| 2   | Age                            | Định lượng | Năm      | Tuổi của cá nhân                                                                                                                                                             |
| 3   | Height                         | Định lượng | m        | Chiều cao                                                                                                                                                                    |
| 4   | Weight                         | Định lượng | kg       | Cân nặng                                                                                                                                                                     |
| 5   | Family_history_with_overweight | Nhị phân   | 0/1      | Cho biết liệu gia đình có thành viên nào thừa cân hay có vấn đề về cân nặng. Với <i>No</i> = không; <i>Yes</i> = có                                                          |
| 6   | FAVC                           | Nhị phân   | 0/1      | Có thường xuyên tiêu thụ thức ăn có hàm lượng calo không. Với <i>Yes</i> = có; <i>No</i> = không.                                                                            |
| 7   | FCVC                           | Định lượng | 1-3      | Cho biết cá nhân có thường ăn rau trong bữa ăn không.                                                                                                                        |
| 8   | NCP                            | Định lượng | Lần/ngày | Số bữa ăn chính trong ngày                                                                                                                                                   |
| 9   | CAEC                           | Phân loại  | -        | Thói quen ăn vặt. Với <i>no</i> = không; <i>always</i> = luôn luôn; <i>sometimes</i> = thỉnh thoảng; <i>frequently</i> = thường xuyên.                                       |
| 10  | SMOKE                          | Nhị phân   | 0/1      | Có hút thuốc hay không. Với <i>Yes</i> = có; <i>No</i> = không.                                                                                                              |
| 11  | CH2O                           | Định lượng | Lít/ngày | Lượng nước uống mỗi ngày                                                                                                                                                     |
| 12  | SCC                            | Nhị phân   | 0/1      | Có kiểm soát lượng calo hấp thụ hay không. Với <i>Yes</i> = có; <i>No</i> = không.                                                                                           |
| 13  | FAF                            | Định lượng | Giờ/ngày | Mức độ hoạt động thể chất hàng ngày                                                                                                                                          |
| 14  | TUE                            | Định lượng | Giờ/ngày | Thời gian sử dụng các thiết bị điện tử.                                                                                                                                      |
| 15  | CALC                           | Phân loại  | -        | Tần suất uống đồ có cồn. Với <i>no</i> = không; <i>sometimes</i> = thỉnh thoảng; <i>frequently</i> = thường xuyên.                                                           |
| 16  | MTRANS                         | Phân loại  | -        | Phương tiện di chuyển chính. Với <i>Automobile</i> = xe hơi; <i>Motorbike</i> = xe máy; <i>bike</i> = xe đạp; <i>Public</i> = phương tiện công cộng; <i>Walking</i> = đi bộ. |
| 17  | NObeyesdad                     | Phân loại  | -        | Mức độ béo phì. Với 7 cấp độ cụ thể là Thiếu cân; Cân nặng bình thường; Thừa cân cấp độ I; Thừa cân cấp độ II; Béo phì loại I; Béo phì loại II và Béo phì loại III.          |

## II Kiến thức nền

### 1 Các đặc trưng của tổng thể và mẫu

**Tổng thể:** là tập hợp các phần tử thuộc đối tượng nghiên cứu, được quan sát, thu thập và phân tích theo một hoặc một số đặc trưng nào đó. Các phần tử tạo thành tổng thể thống kê được gọi là đơn vị tổng thể.

**Mẫu:** là một số đơn vị được chọn ra từ tổng thể theo một phương pháp lấy mẫu nào đó. Các đặc trưng mẫu được sử dụng để suy rộng ra các đặc trưng của tổng thể nói chung.

**Các đặc trưng của mẫu:**

+ **Kích thước mẫu:** Số phần tử của mẫu gọi là kích thước mẫu. Ký hiệu:  $n$

+ **Trung bình mẫu:** Với một mẫu có  $n$  phần tử, trung bình mẫu (kí hiệu:  $\bar{x}$ ):

$$\bar{x} = \frac{\sum_{i=1}^n x_i}{n}$$

+ **Phương sai mẫu:** Với một mẫu có  $n$  phần tử, phương sai mẫu (kí hiệu:  $s^2$ ):

$$s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}$$

+ **Độ lệch mẫu:** là căn bậc hai dương của phương sai, ký hiệu :  $s$


+ **Tỷ lệ mẫu:** Với một mẫu có  $n$  phần tử và có  $m$  phần tử mang tính chất  $A$  nào đó. Tỷ lệ mẫu được tính bởi công thức:

$$f \equiv \hat{p} = \frac{m}{n}$$

+ **Trung vị:** Giả sử mẫu có kích thước  $n$  và các phần tử được xếp theo thứ tự tăng dần. Cụ thể:

- Nếu  $n = 2k + 1$  thì trung vị mẫu là giá trị  $x_{k+1}$ .
- Nếu  $n = 2k$  thì trung vị mẫu là giá trị  $\frac{x_k + x_{k+1}}{2}$ .

+ **Tứ phân vị:** Giá trị trung vị chia mẫu dữ liệu đã sắp thứ tự thành 2 tập có số phần tử bằng nhau. Trung vị của tập dữ liệu nhỏ hơn là Q1 (gọi là tứ phân vị dưới) và trung vị của tập dữ liệu lớn hơn là Q3 (gọi là tứ phân vị trên). Q2 được lấy bằng giá trị trung vị.



Hình 1: Ví dụ

Hiệu  $IQR = Q3 - Q1$  được gọi là khoảng tứ phân vị hay độ trải giữa.

- + **Điểm outlier:** Còn gọi là điểm dị biệt, điểm ngoại lệ, điểm ngoại lai. Đó là phần tử của mẫu có giá trị nằm ngoài khoảng  $(Q1 - 1.5 \times IQR; Q3 + 1.5 \times IQR)$ .

## 2 Kiểm định giả thiết thống kê

Trong bài toán kiểm định giả thiết, giả thiết về yếu tố cần kiểm định của tổng thể ở trạng thái bình thường gọi là giả thiết không (null hypothesis), kí hiệu:  $H_0$ . Mệnh đề đối lập với  $H_0$  gọi là đối thiết (hay giả thiết đối) (alternative hypothesis), kí hiệu:  $H_1$ .  $H_1$  thể hiện xu hướng cần kiểm định.

Khi xét bài toán kiểm định giả thiết cho tham số  $\theta$ , ta sẽ có một trong ba cặp giả thiết:

**Kiểm định hai phía:**

$$\begin{cases} H_0 : \theta = \theta_0 & \theta_0 \text{ là giá trị cho trước} \\ H_1 : \theta \neq \theta_0 \end{cases}$$

**Kiểm định bên trái:**

$$\begin{cases} H_0 : \theta = \theta_0 & (\theta \geq \theta_0) \\ H_1 : \theta < \theta_0 \end{cases}$$

**Kiểm định bên phải:**

$$\begin{cases} H_0 : \theta = \theta_0 & (\theta \leq \theta_0) \\ H_1 : \theta > \theta_0 \end{cases}$$

**Miền bác bỏ giả thiết RR** là miền số thực thỏa  $P(G \in RR/H_0 \text{ đúng}) = \alpha$ .  $\alpha$  là một số khá bé, thường không quá 10% và được gọi là mức ý nghĩa của kiểm định.

**Quy tắc kiểm định:** Từ mẫu thực nghiệm, ta tính được một giá trị cụ thể của tiêu chuẩn kiểm định, gọi là giá trị kiểm định thống kê:

$$g_{qs} = G(x_1, x_2, \dots, x_n, \theta)$$

Theo nguyên lý xác suất bé, biến cố  $G \in RR$  có xác suất nhỏ nên với 1 mẫu thực nghiệm ngẫu nhiên, nó không thể xảy ra. Do đó:

- Nếu  $g_{qs} \in RR$ : bác bỏ  $H_0$ , thừa nhận giả thiết  $H_1$ .
- Nếu  $g_{qs} \notin RR$ : chưa đủ dữ liệu khẳng định  $H_0$  sai. Vì vậy ta chưa thể chứng minh được  $H_1$  đúng.

### 3 Phân tích phương sai

#### 3.1 Giả thiết của bài toán ANOVA 1 yếu tố:

- Các tổng thể có phân phối chuẩn  $N(\mu_i, \sigma_i^2)$   $i = 1; 2; \dots; k$  với  $k$  là số tổng thể.
- Phương sai các tổng thể bằng nhau ( $\sigma_1^2 = \sigma_2^2 = \dots = \sigma_k^2$ )
- Các mẫu quan sát (từ các tổng thể) được lấy độc lập.

#### 3.2 Các bước thực hiện bài toán:

##### Bước 1: Đặt giả thiết kiểm định

$$H_0 : \mu_1 = \mu_2 = \dots = \mu$$

(Trung bình của  $k$  tổng thể bằng nhau, tức nhân tố nguyên nhân không có tác động gì đến nhân tố kết quả ta đang nghiên cứu.)

$$H_1 : \exists \mu_i \neq \mu_j (i \neq j)$$

(Có ít nhất một cặp trung bình ở các tổng thể khác nhau, tức nhân tố nguyên nhân có tác động đến nhân tố kết quả ta đang nghiên cứu).

##### Bước 2: Tính giá trị kiểm định thống kê

Tính trung bình mẫu của từng nhóm:

$$\bar{x}_i = \frac{\sum_{j=1}^{n_i} x_{ij}}{n_i} \quad (i = 1, 2, 3, \dots, k)$$

Trung bình chung của toàn bộ mẫu khảo sát:

$$\bar{x} = \frac{\sum_{i=1}^k \sum_{j=1}^{n_i} x_{ij}}{\sum_{i=1}^k n_i}$$

Với  $n_i$  là số quan sát trong mẫu thứ  $i$ .

Tính tổng các chênh lệch bình phương giữa các nhóm  $SSB$ :

$$SSB = n_1(\bar{x}_1 - \bar{x})^2 + n_2(\bar{x}_2 - \bar{x})^2 + \dots + n_k(\bar{x}_k - \bar{x})^2$$

Tính tổng các chênh lệch bình phương trong nội bộ nhóm  $SSW$ :

$$SSW = SSW_1 + SSW_2 + \dots + SSW_k$$

Trong đó:

$$SSW_1 = \sum_{j=1}^{n_1} (x_{1j} - \bar{x}_1)^2 = (x_{11} - \bar{x}_1)^2 + \dots + (x_{1n_1} - \bar{x}_1)^2 : \text{tổng chênh lệch bình phương nhóm 1}$$

Tính tổng các chênh lệch bình phương toàn bộ  $SST$ :

$$SST = SSW + SSB = (n_1 - 1)s_1^2 + \dots + (n_k - 1)s_k^2 = (N - 1)s^2$$

với  $N$  là tổng số quan sát ở toàn bộ các nhóm.

Tính phương sai giữa các nhóm  $MSB$ :

$$MSB = \frac{SSB}{k - 1}$$

Tính phương sai trong nội bộ nhóm:

$$MSW = \frac{SSW}{N - k}$$

Tính giá trị kiểm định thống kê

$$F = \frac{MSB}{MSW}$$

**Bước 3: Xác định miền bác bỏ:**  $RR = (f_{\alpha; k-1; N-k}; +\infty)$

**Bước 4: Kết luận:**

Nếu  $F \in RR \Rightarrow$  đủ cơ sở bác bỏ  $H_0$ , chấp nhận  $H_1$

Nếu  $F \notin RR \Rightarrow$  chưa đủ cơ sở bác bỏ được  $H_0$ , chấp nhận  $H_0$

**Bảng mô hình phân tích phương sai một nhân tố**

| Nguồn của sự biến thiên | SS    | df      | MS    | $F$                   |
|-------------------------|-------|---------|-------|-----------------------|
| Giữa các nhóm           | $SSB$ | $k - 1$ | $MSB$ | $F = \frac{MSB}{MSW}$ |
| Trong từng nhóm         | $SSW$ | $N - k$ | $MSW$ |                       |
| Toàn bộ                 | $SST$ | $N - 1$ |       |                       |

**Hệ số xác định  $R^2$ :**

$$R^2 = \frac{SSB}{SST} \times 100\%$$

Hệ số xác định  $R^2$  của mô hình Phân tích phương sai được sử dụng để đo mức độ ảnh hưởng của yếu tố được xem xét trong mô hình đối với sự biến động của các giá trị của biến ngẫu nhiên  $X$  quanh giá trị trung bình của nó.  $R^2$  càng lớn thì mô hình càng thích hợp.



**Phương pháp LSD:** so sánh lần lượt tất cả các cặp trung bình của 2 nhóm khác nhau với giả thuyết tương ứng:

$$H_o : \mu_i = \mu_j$$

$$H_1 : \mu_i \neq \mu_j, i \neq j$$

Với:

$$LSD = t_{\alpha/2}^{N-k} \cdot \sqrt{MSW \cdot \left( \frac{1}{n_i} + \frac{1}{n_j} \right)}, i \neq j \text{ và } i, j \in \{1, 2, \dots, k\}.$$

$$\text{Khi } n_1 = n_2 = \dots = n \Rightarrow LSD = t_{\alpha/2}^{N-k} \cdot \sqrt{\frac{2MSW}{n}}$$

Giả thuyết  $H_o$  bị bác bỏ khi:  $|\bar{x}_i - \bar{x}_j| > LSD$

**Phương pháp khoảng tin cậy (LSD confidence intervals):** ước lượng các chênh lệch của trung bình hai nhóm bất kỳ, từ đó tìm ra các cặp nhóm có trung bình khác biệt. Khoảng tin cậy LSD cho chênh lệch trung bình:

$$\mu_i - \mu_j = \bar{x}_i - \bar{x}_j \pm LSD.$$

Nếu khoảng tin cậy không chứa số 0 thì ta nói có sự khác biệt giữa hai giá trị trung bình  $\mu_i, \mu_j$  (hay là sự khác biệt có ý nghĩa thống kê). Cụ thể hơn, nếu khoảng tin cậy chỉ gồm số dương, xem như  $\mu_i > \mu_j$ . Ngược lại, nếu khoảng tin cậy chỉ gồm các số âm, xem như  $\mu_i < \mu_j$ .

Nếu khoảng tin cậy chứa số 0 thì ta không kết luận được có sự khác biệt giữa  $\mu_i, \mu_j$  (chấp nhận  $H_o$ ).

Ngoài ra, ta có thể tìm khoảng tin cậy cho  $\mu_i$  có dạng:

$$\bar{x}_i \pm t_{\alpha/2}^{N-k} \cdot \sqrt{\frac{MSW}{n_i}}$$

Với:

$$SE_i = SE(\bar{X}_i) = \sqrt{\frac{MSW}{n_i}} \text{ là sai số chuẩn của trung bình nhóm } i.$$

$$SE_{i,j} = SE(\bar{X}_i - \bar{X}_j) = \sqrt{MSW \cdot \left( \frac{1}{n_i} + \frac{1}{n_j} \right)}$$

là sai số chuẩn của hiệu 2 trung bình giữa nhóm  $i$  và nhóm  $j$ .

Số khoảng tin cậy cần tìm:  $C_k^2$

## 4 Hồi quy Logistic có thứ tự (ordinal logistic)

### 4.1 Khái niệm

Biến thứ tự là một biến phân loại trong đó các mức độ có thứ tự tự nhiên (ví dụ: trầm cảm được phân loại thành tối thiểu, nhẹ, trung bình, trung bình nặng và nặng).

Hồi quy Logistic thứ tự (Ordinal Logistic Regression - OLR) là một phương pháp thống kê được sử dụng khi biến phụ thuộc (biến mục tiêu) là biến định tính có thứ bậc (Ordinal), có nghĩa là các cấp độ của biến có thể được sắp xếp theo một thứ tự tự nhiên, nhưng khoảng cách giữa các cấp độ không nhất thiết phải bằng nhau.

**Mục đích:** Mục tiêu của mô hình là dự đoán xác suất một trường hợp rơi vào một danh mục cụ thể hoặc thấp hơn danh mục đó, dựa trên các biến độc lập ( $X_1, X_2, \dots, X_p$ ).

Trong đề tài này: biến mục tiêu NObeyesdad có 7 cấp độ được sắp xếp thứ tự từ thấp đến cao: Insufficient\_Weight <  $\dots$  < Obesity\_Type\_III. OLR được sử dụng để phân tích các yếu tố (BMI, Age,...) ảnh hưởng đến việc một cá nhân chuyển sang mức độ béo phì cao hơn.

Mô hình hồi quy logistic thứ tự: phương trình hồi quy logistic thứ tự biểu diễn mối quan hệ toán học giữa các biến dự báo và tỷ lệ logarit của một quan sát thuộc một phạm trù thứ tự cụ thể hoặc một phạm trù thấp hơn.

Công thức tổng quát thường được biểu diễn như sau: Mô hình hoạt động bằng cách ước tính Logarit của Tỷ lệ Chênh lệch Tích lũy (Cumulative Log-Odds). Nếu biến  $Y$  có  $M$  danh mục, mô hình sẽ có  $M - 1$  phương trình:

$$\text{logit}(P(Y \leq j)) = \log \left( \frac{P(Y \leq j)}{1 - P(Y \leq j)} \right) = \beta_{j0} + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p$$

Trong đó:

- $Y$ : Biến phụ thuộc thứ tự (có  $M$  danh mục).
- $j$ : Là một ngưỡng danh mục, chạy từ 1 đến  $M - 1$ . Ví dụ, nếu có 4 danh mục (1, 2, 3, 4), sẽ có 3 ngưỡng ( $j = 1, 2, 3$ ).
- $P(Y \leq j)$ : Xác suất tích lũy (Cumulative Probability) biến phụ thuộc rơi vào danh mục  $j$  hoặc bất kỳ danh mục nào nhỏ hơn  $j$ .
- $\frac{P(Y \leq j)}{1 - P(Y \leq j)}$ : Tỷ lệ Chênh lệch Tích lũy (Cumulative Odds) hay có thể hiểu là

$$\text{Log-Odds} = \log \left( \frac{\text{Xác suất thuộc Lower Category}}{\text{Xác suất thuộc Higher Category}} \right)$$

- $\text{logit}(\cdot)$ : Hàm Logit, biến đổi xác suất thành log-odds.
- $\beta_{j0}$  (hoặc  $\kappa_j, \alpha_j$ ): Ngưỡng chặn (Threshold Intercept) riêng cho mỗi ngưỡng  $j$ . Mỗi ngưỡng có một giá trị chặn khác nhau.
- $\beta_1, \beta_2, \dots, \beta_p$ : Các hệ số hồi quy (Slope Coefficients) tương ứng với các biến độc lập  $X_1, X_2, \dots, X_p$ .

**Điểm đặc trưng:** các hệ số hồi quy  $(\beta_1, \beta_2, \dots, \beta_p)$  là như nhau ( $\beta_k$  không có chỉ số  $j$ ) đối với tất cả các ngưỡng  $j$ . Nghĩa rằng ảnh hưởng của các biến độc lập lên tỷ lệ chênh lệch tích lũy là nhất quán trên các điểm cắt (thứ tự) của biến phụ thuộc. Đây còn được gọi là giả định "Đường song song" (Parallel Lines Assumption).

#### 4.2 Giả định tỉ lệ chênh lệch tích lũy (Proportional Odds Assumption)

**Tỉ lệ chênh lệch (Odds):** được tính bằng tỷ lệ giữa xác suất "thành công" ( $P$ ) và xác suất "thất bại" ( $1 - P$ ):

$$\text{Odds} = \frac{P}{1 - P}$$

Trong mô hình hồi quy logistic có thứ tự, "thành công" được định nghĩa là việc biến kết quả  $Y$  rơi vào một mức độ  $j$  hoặc thấp hơn ( $Y \leq j$ ). Odds tích lũy được tính là:

$$\text{Odds}_j = \frac{P(Y \leq j)}{P(Y > j)}$$

Tức là, tỷ lệ chênh lệch của việc có kết quả theo hướng thấp hơn (hoặc ít nghiêm trọng hơn) so với việc có kết quả theo hướng cao hơn (hoặc nghiêm trọng hơn) tại một ngưỡng  $j$  nhất định.

**Tỷ lệ chênh lệch tích lũy (Cumulative Odds Ratio - OR):** là kết quả của việc lũy thừa hóa (exponentiating) hệ số hồi quy ( $\beta$ ) của biến độc lập.

$$\text{OR} = e^\beta$$

OR này mô tả mức độ thay đổi của Odds tích lũy khi biến độc lập thay đổi một đơn vị (hoặc chuyển từ nhóm tham chiếu sang nhóm khác đối với biến phân loại).

#### **Giả định tỷ lệ chênh lệch tỷ lệ (Proportional Odds Assumption - POA)**

Ảnh hưởng của mỗi biến độc lập ( $X$ ) lên logarit của tỷ lệ chênh lệch tích lũy (log-odds) là nhất quán (tức là không đổi) trên tất cả các ngưỡng (điểm cắt) của biến phụ thuộc thứ tự ( $Y$ ).

**Giải thích:** Mô hình hồi quy logistic có thứ tự sẽ có các hệ số chặn (intercepts) khác nhau ( $\alpha_j$ ) tại mỗi ngưỡng chia cắt giữa các cấp độ của biến kết quả (ví dụ: Very Liberal | Slightly Liberal, Slightly Liberal | Moderate, v.v.). Tuy nhiên, mô hình chỉ có duy nhất một tỷ lệ chênh lệch (Odds Ratio -  $e^\beta$ ) cho tác động của mỗi biến độc lập. Điều này có nghĩa là, tỷ lệ chênh lệch tích lũy giữa hai nhóm (ví dụ: Dân chủ và Cộng hòa) là tỷ lệ (Proportional) và không thay đổi qua tất cả các ngưỡng phân chia của biến kết quả.

Tóm lại:

- Các Hệ số Hồi quy ( $\beta_k$ ): Trong mô hình này, các hệ số hồi quy của biến độc lập ( $\beta_1, \beta_2, \dots$ ) là giống nhau (không có chỉ số  $j$ ) đối với mọi ngưỡng  $j$ .
- Các Ngưỡng chặn ( $\beta_{j0}$ ): Chỉ có các giá trị chặn ( $\beta_{j0}$ ) là khác nhau giữa các ngưỡng.

#### 4.3 Diễn giải hệ số (Odds Ratio - OR)

Việc diễn giải kết quả của mô hình Logistic Thứ tự được thực hiện thông qua Tỷ lệ Chênh lệch Tích lũy (Cumulative Odds Ratio). Tỷ lệ Chênh lệch Tích lũy (Cumulative Odds) cho ngưỡng  $j$  là:

$$\text{Odds}(Y \leq j) = \frac{P(Y \leq j)}{P(Y > j)}$$

Giá trị OR được tính bằng cách lấy lũy thừa của hệ số hồi quy:

$$OR_k = \exp(\beta_k)$$

OR trong mô hình này được gọi là tỷ lệ chênh lệch tỷ lệ (Proportional Odds Ratio) hoặc tỷ lệ chênh lệch toàn bộ (Global Odds Ratio) vì nó áp dụng nhất quán cho tất cả các ngưỡng  $j$ . Việc diễn giải luôn phải gắn với "tỷ lệ chênh lệch tích lũy" và "tăng/giảm một đơn vị" của biến độc lập: Giá trị của  $\exp(\beta_k)$  Ý nghĩa

- $OR_k > 1$ : Tăng một đơn vị trong biến  $X_k$  sẽ làm tăng  $OR_k$  lần tỷ lệ chênh lệch để biến  $Y$  rơi vào các danh mục cao hơn.
- $OR_k < 1$ : Tăng một đơn vị trong biến  $X_k$  sẽ làm giảm  $OR_k$  lần tỷ lệ chênh lệch để biến  $Y$  rơi vào các danh mục cao hơn (tức là tăng khả năng rơi vào các danh mục thấp hơn).
- $OR_k = 1$ : Biến  $X_k$  không có ảnh hưởng đến tỷ lệ chênh lệch tích lũy.

## 5 Bản đồ nhiệt (Heatmap)


Bản đồ nhiệt là một biểu diễn dữ liệu hai chiều ở dạng biểu đồ, trong đó các giá trị khác nhau được thể hiện bằng màu sắc. Đặc điểm chung của tất cả các bản đồ nhiệt là chúng sử dụng các màu sắc hoặc sắc độ khác nhau của cùng một màu để biểu thị các giá trị khác nhau và thể hiện mối quan hệ của các biến được biểu diễn trên trục x và trục y.

### 5.1 Màu sắc trong bản đồ nhiệt

Có ba loại bảng màu chính dùng trong trực quan hóa dữ liệu:


- Bảng màu định tính (Qualitative palettes)
- Bảng màu tuần tự (Sequential palettes)
- Bảng màu phân kỳ (Diverging palettes)

**Bảng màu định tính (Qualitative palettes)** Sử dụng bảng màu định tính khi các biến có tên riêng biệt hoặc dữ liệu phân loại. Trong bảng màu định tính, mỗi màu được gán cho một biến riêng biệt, ta cần cố gắng giới hạn tối đa số màu (thường sử dụng ít hơn 10 màu) để tránh khó khăn giữa việc phân biệt của các nhóm. Có thể gộp các nhóm có tỉ lệ nhỏ chung thành một danh mục "Khác" để tối ưu số màu sử dụng.




Hình 2: Biểu đồ tròn sử dụng bảng màu định tính

**Bảng màu tuần tự (Sequential palettes)** Khi các biến có giá trị số, làm thành một chuỗi hoặc có thứ tự cụ thể, thì nó có thể được mô tả bằng bảng màu tuần tự. Màu sắc được gán cho các giá trị dữ liệu theo dạng liên tục, thường dựa trên độ sáng, sắc độ, hoặc cả hai.



**Hình 3:** Biểu đồ sử dụng bảng màu tuần tự


Thông thường, các giá trị cao sẽ có màu tối hơn và các giá trị thấp sẽ có màu sáng hơn.



**Hình 4:** Sự tương quan giữa sắc độ màu và giá trị biến

**Bảng màu phân kỳ (Diverging palettes)** Nếu các biến có giá trị trung tâm (chẳng hạn như số 0) thì nên sử dụng bảng màu phân kỳ. Bảng màu phân kỳ về cơ bản là sự kết hợp của hai bảng màu tuần tự với một điểm cuối chung nằm ở giá trị trung tâm. Các giá trị lớn hơn giá trị trung tâm được gán cho các màu ở một bên của giá trị trung tâm, trong khi các giá trị nhỏ hơn được gán cho các màu ở phía đối diện.

Thông thường, ta sẽ sử dụng 2 sắc thái riêng để giúp phân biệt dễ dàng hơn giữa các giá trị dương và âm so với tâm.



**Hình 5:** Biểu đồ sử dụng bảng màu phân kỳ

Một lưu ý là bản đồ nhiệt thường phải có chú thích về cách màu sắc ánh xạ thành các giá trị số. Vì bản thân màu sắc không có mối liên hệ cố định với giá trị, nên các chú thích rất quan trọng để người xem nắm bắt các giá trị trong bản đồ nhiệt.

## 5.2 Đồ thị tương quan (Correlogram)

Correlogram (hay còn gọi là correlation matrix heatmap, correlation plot) là Biểu đồ tương quan là biểu diễn đồ họa về mối quan hệ giữa từng cặp biến trong một tập dữ liệu.

### Cấu trúc của đồ thị

- Correlogram luôn là một ma trận vuông ( $n \times n$ ), với  $n$  là số lượng biến (cột) trong dữ liệu.
- Mỗi hàng đại diện cho một biến.
- Mỗi cột cũng đại diện cho một biến (thường trùng tên với hàng để tạo đối xứng).
- Đường chéo chính: Luôn có giá trị 1.00 (hoặc 100% tương quan), vì đây là tương quan của biến với chính nó. Thường được tô màu đậm nhất (ví dụ: xanh đen hoặc đỏ đậm, tùy palette).
- Tính đối xứng: Ma trận đối xứng qua đường chéo chính, nghĩa là  $\rho(i, j) = \rho(j, i)$ . Ví dụ, tương quan giữa Age và BMI giống hệt BMI và Age. Do đó, ta chỉ cần đọc nửa trên hoặc nửa dưới để tránh lặp lại.

**Màu sắc của đồ thị** Thanh màu (colorbar): Thường nằm bên phải hoặc dưới đồ thị, thể hiện thang đo từ giá trị thấp nhất đến cao nhất của hệ số tương quan (thường từ -1 đến +1).

- Màu dương (+): Thể hiện tương quan dương (cùng chiều) nghĩa là tăng biến A  $\rightarrow$  tăng biến B. Ví dụ: màu càng đậm (ví dụ: xanh dương đậm) chứng tỏ tương quan dương càng mạnh.
- Màu âm (-): Thể hiện tương quan âm (ngược chiều) nghĩa là tăng biến A  $\rightarrow$  giảm biến B. Ví dụ: màu càng đậm (ví dụ: đỏ cam đậm)  $\rightarrow$  tương quan âm càng mạnh.
- Màu trung lập (gần 0): Thường là trắng hoặc xám nhạt, nghĩa là không hoặc rất ít tương quan.

### III Tiền xử lý dữ liệu

Quá trình tiền xử lý dữ liệu nhằm làm sạch dữ liệu thô từ tập tin ObesityDataSet\_raw\_and\_data\_synthetic.csv, chuyển đổi kiểu dữ liệu và chuẩn hóa các biến, lọc các dữ liệu ngoại lai để sẵn sàng cho quá trình phân tích thống kê và xây dựng mô hình dự đoán Mức độ béo phì (NObeyesdad).

#### 1 Đọc và Kiểm tra Dữ liệu

Đầu tiên, ta đọc tập dữ liệu bằng R (sử dụng RStudio) thông qua hàm read.csv() hoặc read\_csv(). Sau khi đọc dữ liệu thành công, ta sử dụng lệnh head() hiển thị thông tin của 6 quan sát đầu tiên để kiểm tra dữ liệu đã được nạp vào RStudio (mà không bị lỗi), để quan sát nội dung của tập dữ liệu. Kết quả được trình bày ở hình dưới:

```
1 data_obesity <- read_csv("ObesityDataSet_raw_and_data_synthetic
  .csv")
2 head(data_obesity)
```

|   | Gender<br><chr> | Age<br><dbl> | Height<br><dbl> | Weight<br><dbl> | family_history_with_ov...<br><chr> | FAVC<br><chr> | FCVC<br><dbl> | NCP<br><dbl> | CAEC<br><chr> | SMOKE<br><chr> | CH2O<br><dbl> | SCC<br><chr> |
|---|-----------------|--------------|-----------------|-----------------|------------------------------------|---------------|---------------|--------------|---------------|----------------|---------------|--------------|
| 1 | Female          | 21           | 1.62            | 64              | yes                                | no            | 2             | 3            | Some...       | no             | 2             | no           |
| 2 | Female          | 21           | 1.52            | 56              | yes                                | no            | 3             | 3            | Some...       | yes            | 3             | yes          |
| 3 | Male            | 23           | 1.8             | 77              | yes                                | no            | 2             | 3            | Some...       | no             | 2             | no           |
| 4 | Male            | 27           | 1.8             | 87              | no                                 | no            | 3             | 3            | Some...       | no             | 2             | no           |
| 5 | Male            | 22           | 1.78            | 89.8            | no                                 | no            | 2             | 1            | Some...       | no             | 2             | no           |
| 6 | Male            | 29           | 1.62            | 53              | no                                 | yes           | 2             | 3            | Some...       | no             | 2             | no           |

Hình 6

Tiếp theo ta cần kiểm tra cấu trúc và kiểu dữ liệu của các biến ban đầu sử dụng hàm str(), kết quả trả về sẽ là một bảng tóm tắt súc tích chi tiết về các thông tin của biến gồm: định loại biến (định lượng hay định tính) và cấu trúc biến (tên biến, kiểu dữ liệu: chr - character/chuỗi, num - number/số,... cùng các giá trị ban đầu trong biến đó)

```
1 Code: str(data_obesity)
```

```
> str(data_obesity)
spec_tbl_ [2,111 x 17] (S3: spec_tbl_df/tbl_df/tbl/data.frame)
 $ Gender      : chr [1:2111] "Female" "Female" "Male" "Male" ...
 $ Age         : num [1:2111] 21 21 23 27 22 29 23 22 24 22 ...
 $ Height      : num [1:2111] 1.62 1.52 1.8 1.8 1.78 1.62 1.5 1.64 1.72 ...
 $ Weight      : num [1:2111] 64 56 77 87 89.8 53 55 53 64 68 ...
 $ family_history_with_overweight: chr [1:2111] "yes" "yes" "yes" "no" ...
 $ FAVC        : chr [1:2111] "no" "no" "no" "no" ...
 $ FCVC        : num [1:2111] 2 3 2 3 2 2 3 2 3 2 ...
 $ NCP         : num [1:2111] 3 3 3 3 1 3 3 3 3 3 ...
 $ CAEC        : chr [1:2111] "Sometimes" "Sometimes" "Sometimes" "Sometimes" ...
 $ SMOKE       : chr [1:2111] "no" "yes" "no" "no" ...
 $ CH2O        : num [1:2111] 2 3 2 2 2 2 2 2 2 2 ...
 $ SCC         : chr [1:2111] "no" "yes" "no" "no" ...
 $ FAF         : num [1:2111] 0 3 2 2 0 0 1 3 1 1 ...
 $ TUE         : num [1:2111] 1 0 1 0 0 0 0 0 1 1 ...
 $ CALC        : chr [1:2111] "no" "Sometimes" "Frequently" "Frequently" ...
 $ MTRANS      : chr [1:2111] "Public_Transportation" "Public_Transportation" "Public_Transportation" "Public_Transportation" "walking" ...
 $ NObeyesdad   : chr [1:2111] "Normal_Weight" "Normal_Weight" "Normal_Weight" "Overweight_Level_I" ...
```

Hình 7

Dữ liệu ban đầu gồm 2.111 quan sát và 17 biến, phần lớn các biến phân loại và nhị phân được đọc dưới dạng chuỗi ký tự (character) hoặc số thực (double), yêu cầu phải chuyển đổi kiểu dữ liệu.

## 2 Xử lý và chuyển đổi kiểu dữ liệu

Thực hiện chuyển đổi kiểu dữ liệu (Data Type Conversion) cho các biến phân loại và sắp xếp thứ tự cho biến mục tiêu:

### Chuyển đổi sang Factor:

Các biến nhị phân (Gender, family\_history\_with\_overweight, FAVC, SMOKE, SCC) và các biến phân loại định danh (CAEC, CALC, MTRANS) được chuyển đổi sang kiểu Factor (yếu tố) vì mô hình thống kê (cụ thể là Hồi quy Logistic) không thể xử lý trực tiếp các biến dưới dạng chuỗi ký tự.

```
1 Gender = as.factor(Gender),
2 family_history_with_overweight = as.factor('family_history_with_
   _overweight')
3 FAVC = as.factor(FAVC),
4 CAEC = as.factor(CAEC),
5 SMOKE = as.factor(SMOKE),
6 SCC = as.factor(SCC),
7 CALC = as.factor(CALC),
8 MTRANS = as.factor(MTRANS),
```

**Sắp xếp thứ tự biến mục tiêu:** Biến mục tiêu NObeyesdad (Mức độ béo phì), là biến định tính có thứ bậc (Ordinal Variable) với 7 cấp độ, được chuyển đổi thành Ordered Factor (yếu tố có thứ tự). Thứ tự các cấp độ được xác định là: Insufficient Weight < Normal Weight < Overweight Level I < Overweight Level II < Obesity Type I < Obesity Type II < Obesity Type III

```
1 NObeyesdad = factor(NObeyesdad, levels = c("Insufficient_
   Weight", "Normal_Weight", "Overweight_Level_I", "Overweight_
   Level_II", "Obesity_Type_I", "Obesity_Type_II", "Obesity_
   Type_III"), ordered = TRUE)
```

## 3 Xử lý biến và tạo chỉ số BMI

Tạo biến BMI: Tạo thêm chỉ số BMI (Body Mass Index) để thay thế cho hai biến độc lập có độ tương quan cao với nhau là cân nặng (Weight) và chiều cao (Height) sử dụng hàm mutate().

$$BMI = \frac{Weight}{Height^2}$$

```
1 mutate(BMI = Weight / (Height^2)) %>%
```



Loại bỏ Biến dư thừa: Sau khi tạo biến BMI, các biến gốc Weight và Height trở nên dư thừa và cần được loại bỏ khỏi mô hình để tránh trùng lặp.

## 4 Xử lý giá trị ngoại lai (Outlier)

**Phần 1:** Đếm số lượng outlier trong dữ liệu:

```
1 check_outliers <- function(df) {
2   num <- df[, sapply(df, is.numeric), drop = FALSE]
3   outlier_stats <- sapply(num, function(x) {
4     # Tính toán IQR
5     x_clean <- na.omit(x)
6     Q1 <- quantile(x_clean, 0.25)
7     Q3 <- quantile(x_clean, 0.75)
8     IQR_val <- Q3 - Q1
9     lower_bound <- Q1 - 1.5 * IQR_val
10    upper_bound <- Q3 + 1.5 * IQR_val
11
12    count <- sum(x_clean < lower_bound | x_clean > upper_bound)
13    total <- length(x_clean)
14    percent <- round((count / total) * 100, 2)
15    return(c(Count = count, Percent = percent))
16  })
17  outlier_df <- as.data.frame(t(outlier_stats)) %>%
18    mutate(Percent = paste0(Percent, "%"))
19  return(outlier_df)
20 }
21 check_outliers(Obesity)
```

- Kết quả:

|      | Count | Percent |
|------|-------|---------|
| Age  | 168   | 7.96%   |
| FCVC | 0     | 0%      |
| NCP  | 579   | 27.43%  |
| CH2O | 0     | 0%      |
| FAF  | 0     | 0%      |
| TUE  | 0     | 0%      |
| BMI  | 0     | 0%      |

Nhận xét: Trong số các biến định lượng, có thể thấy tỉ lệ outlier của biến Age và NCP khá cao.

**Phần 2:** Vẽ biểu đồ histogram với 2 biến Age và NCP

- Tiếp theo ta sẽ vẽ biểu đồ histogram cho 2 biến này để kiểm tra


```
1 ggplot(Obesity, aes(x = Age)) +
2   geom_histogram(fill = "steelblue", color = "black", bins =
3     30) +
```

```

3  labs(title = "Histogram của Age",
4      x = "Age",
5      y = "Tần số") +
6  theme_minimal()
7
8  ggplot(Obesity, aes(x = NCP)) +
9  geom_histogram(fill = "lightgreen", color = "black", bins =
10     30) +
11  labs(title = "Histogram của NCP",
12      x = "NCP",
13      y = "Tần số") +
14  theme_minimal()


```

- Kết quả:



Hình 8: Histogram của Age

Nhận xét: Đối với Age, biểu đồ có phân bố lệch phải, phần lớn người trong mẫu nằm trong độ tuổi từ 18-25, và số lượng người lớn tuổi giảm dần.



Hình 9: Histogram của NCP

Nhận xét: Biểu đồ cho thấy giá trị tập trung cao nhất ở mức 3 buổi/ ngày, thể hiện thói

quen ăn uống phổ biến.

### Phần 3: Xử lý ngoại lai bằng phương pháp Capping

Đề xuất: chúng ta sẽ thực hiện phương pháp Capping để thay thế outlier cho biến Age và giữ nguyên đối với biến NCP. Tỷ lệ outlier của NCP tới 27.43% ngoại lai, điều này cho thấy các giá trị này là phản ánh tính chất tự nhiên của biến (nhiều người có thể ăn 1 hay 4 bữa/ ngày). Vậy nên việc thay thế outlier đối với NCP sẽ dẫn tới việc mất mát đa dạng của dữ liệu

```
1 handle_outliers<- function(x) {  
2   Q1 <- quantile(x, 0.25, na.rm = TRUE)  
3   Q3 <- quantile(x, 0.75, na.rm = TRUE)  
4   IQR_val <- Q3 - Q1  
5   Lower_Bound <- Q1 - 1.5 * IQR_val  
6   Upper_Bound <- Q3 + 1.5 * IQR_val  
7  
8   x[x < Lower_Bound] <- Lower_Bound  
9   x[x > Upper_Bound] <- Upper_Bound  
10  return(x)  
11 }  
12 Obesity$Age <- handle_outliers(Obesity$Age)
```

## IV Thống kê mô tả

### 1 Tính toán các giá trị thống kê mô tả

a) **Biến định lượng:** Đối với các biến định lượng, ta thực hiện tính thống kê mô tả (bao gồm phân vị 1, trung vị, trung bình mẫu, phân vị 3, độ lệch chuẩn mẫu, giá trị nhỏ nhất và giá trị lớn nhất ) theo từng nhóm béo phì.

```
1 num_vars <- c("Age", "FCVC", "NCP", "CH2O", "FAF", "TUE", "BMI")
2 des_func <- function(x) {
3   sapply(x, function(y) c(
4     Min = min(y, na.rm = TRUE),
5     Q1 = quantile(y, 0.25, na.rm = TRUE),
6     Median = median(y, na.rm = TRUE),
7     Mean = mean(y, na.rm = TRUE),
8     Q3 = quantile(y, 0.75, na.rm = TRUE),
9     Max = max(y, na.rm = TRUE),
10    SD = sd(y, na.rm = TRUE)
11  ))
12 }
13 by(Obesity[, num_vars], Obesity$NObeyesdad, des_func)
```

- Kết quả:

```
Obesity$NObeyesdad: Insufficient_weight
      Age      FCVC      NCP      CH2O      FAF      TUE      BMI
Min 16.000000 1.0000000 1.0000000 1.0000000 0.0000000 0.0000000 12.9986849
Q1.25% 18.000000 2.0000000 2.9983025 1.3032237 0.4255463 0.1479900 17.0955011
Median 19.244594 2.7083155 3.0000000 2.0000000 1.3399145 1.0000000 17.5474547
Mean 19.768822 2.4807884 2.9144032 1.8712810 1.2501313 0.8394591 17.4042455
Q3.75% 21.000000 3.0000000 3.5409213 2.2062712 2.0000000 1.2547035 17.9062450
Max 35.079212 3.0000000 4.0000000 3.0000000 3.0000000 2.0000000 19.0822059
SD 2.574248 0.5847967 0.9012679 0.6022948 0.8566248 0.6432312 0.7862307

Obesity$NObeyesdad: Normal_weight
      Age      FCVC      NCP      CH2O      FAF      TUE      BMI
Min 14.000000 1.0000000 1.0000000 1.0000000 0.0000000 0.0000000 18.491124
Q1.25% 19.000000 2.0000000 3.0000000 1.0000000 0.0000000 0.0000000 20.673154
Median 21.000000 2.0000000 3.0000000 2.0000000 1.0000000 1.0000000 22.145329
Mean 21.54897 2.3344948 2.7386760 1.8501742 1.247387 0.6759582 22.014147
Q3.75% 23.000000 3.0000000 3.0000000 2.0000000 2.0000000 1.0000000 23.688544
Max 35.07921 3.0000000 4.0000000 3.0000000 3.0000000 2.0000000 24.913495
SD 4.18375 0.5909827 0.8718614 0.6383915 1.016362 0.6866970 1.842017
```

Hình 10: Nhóm ít nguy cơ (bao gồm thiếu cân và bình thường)

```
Obesity$NObeyesdad: overweight_Level_I
      Age      FCVC      NCP      CH2O      FAF      TUE      BMI
Min 16.000000 1.0000000 1.0000000 1.0000000 0.0000000 0.0000000 22.8267386
Q1.25% 19.624430 2.0000000 1.3200615 1.680972 0.3238015 0.0000000 25.5779690
Median 21.045204 2.0000000 3.0000000 2.0000000 1.0000000 0.3631595 25.9779322
Mean 23.104185 2.2646313 2.5042184 2.058725 1.0567960 0.6129923 25.9907723
Q3.75% 24.219639 2.7800440 3.0000000 2.565740 1.6464737 1.0000000 26.3885582
Max 35.079212 3.0000000 4.0000000 3.0000000 3.0000000 2.0000000 28.7696074
SD 5.253492 0.4826263 0.9628109 0.615209 0.8515997 0.6777136 0.6608222

Obesity$NObeyesdad: overweight_Level_II
      Age      FCVC      NCP      CH2O      FAF      TUE      BMI
Min 17.000000 1.0000000 1.0000000 1.0000000 0.0000000 0.0000000 25.7135131
Q1.25% 21.00032 2.0000000 1.972790 1.7959545 0.1210170 0.0000000 27.6129923
Median 24.00000 2.0000000 2.978500 2.0000000 0.9607160 0.7542745 28.1524166
Mean 26.07324 2.2605781 2.495529 2.0251332 0.9580723 0.6972746 28.2152323
Q3.75% 33.00000 2.6958560 3.000000 2.2626508 1.4386720 1.0000000 28.8891958
Max 35.07921 3.0000000 4.000000 3.0000000 3.0000000 2.0000000 30.3628767
SD 6.11902 0.4532723 0.752908 0.5539598 0.8247436 0.5884358 0.8278624
```

Hình 11: Nhóm thừa cân

```
obesity$NObeyesdad: obesity_Type_I
  Age  FCVC  NCP  CH20  FAF  TUE  BMI
Min 15.000000 1.0000000 1.0000000 1.0000000 0.0000000 0.0000000 29.911958
Q1.25% 20.875385 2.0000000 1.7543390 1.7530000 0.0170585 0.0000000 31.370619
Median 22.975526 2.0000000 3.0000000 2.0149900 0.9906420 0.5376590 32.200035
Mean 24.980287 2.1860499 2.4318617 2.1122185 0.9867483 0.6767428 32.255636
Q3.75% 29.781305 2.4025485 3.0000000 2.6576070 1.6925175 1.2131400 32.973741
Max 35.079212 3.0000000 3.0000000 3.0000000 3.0000000 2.0000000 35.171095
SD 6.081667 0.4319979 0.7894714 0.6246441 0.8946746 0.6878970 1.130957

obesity$NObeyesdad: obesity_Type_II
  Age  FCVC  NCP  CH20  FAF  TUE  BMI
Min 20.000000 1.0000000 1.0000000 1.0000000 0.0000000 0.0000000 34.048509
Q1.25% 24.582200 2.0688340 2.7016890 1.4132180 0.5826860 0.0000000 35.750525
Median 27.186873 2.4323550 3.0000000 2.0012080 0.9944220 0.343635 36.417803
Mean 27.847903 2.3912836 2.7445549 1.8776579 0.9718570 0.515186 36.723424
Q3.75% 30.715160 2.8260360 3.0000000 2.1654080 1.3762170 0.863740 37.880693
Max 35.079212 3.0000000 4.0000000 3.0000000 2.0000000 2.0000000 39.786652
SD 4.060586 0.4898081 0.5787654 0.5531227 0.5812384 0.563862 1.290127

obesity$NObeyesdad: obesity_Type_III
  Age  FCVC  NCP  CH20  FAF  TUE  BMI
Min 18.000000 3 3 1.000000 0.0000000 0.0000000 36.774400
Q1.25% 21.020867 3 3 1.665423 0.0000000 0.4130310 40.591185
Median 25.369387 3 3 2.431036 0.2226535 0.6568560 41.942617
Mean 23.495554 3 3 2.208493 0.6648171 0.6046227 42.273746
Q3.75% 26.000000 3 3 2.692467 1.4612475 0.8537010 43.838604
Max 26.000000 3 3 3.000000 2.0000000 1.0000000 50.811753
SD 2.764324 0 0 0.603782 0.7328641 0.2818518 2.578689
```

Hình 12: Nhóm béo phì

b) **Biến phân loại:** Đối với các biến phân loại, ta lập bảng thống kê số lượng nhằm đếm số lần xuất hiện của từng loại.

```
1 categorical_vars <- c("Gender", "family_history_with_overweight",
2 "FAVC", "CAEC", "SMOKE", "SCC",
3 "CALC", "MTRANS", "NObeyesdad")
4 freq_tables <- sapply(Obesity[, categorical_vars], table)
5 print(freq_tables)
```

```
$Gender
  Female  Male
1043    1068

$family_history_with_overweight
  no  yes
385 1726

$FAVC
  no  yes
245 1866

$CAEC
  Always Frequently  no  Sometimes
53      242      51      1765

$SMOKE
  no  yes
2067  44

$SCC
  no  yes
2015  96

$CALC
  Always Frequently  no  Sometimes
1      70      639      1401

$MTRANS
  Automobile  Bike  Motorbike  Public_Transportation  walking
457          7      11          1580          56

$NObeyesdad
  Insufficient_weight  Normal_weight  Overweight_Level_I  Overweight_Level_II  obesity_Type_I  obesity_Type_II
272                287                290                290                351                297
obesity_Type_III
324
```


Hình 13: Kết quả

Nhận xét: Ta thấy sự phân bố đa dạng trong các yếu tố nguy cơ liên quan đến béo phì

## 2 Sử dụng đồ thị để mô tả dữ liệu

### a) Count plot:

```
1 p0_count <- ggplot(Obesity, aes(x = NObeyesdad)) +
2   geom_bar(fill = "steelblue", color = "black") +
3   labs(title = "Tần số các mức độ béo phì (NObeyesdad)",
4         x = "Mức độ Béo phì",
5         y = "Số lượng") +
6   theme_minimal() +
7   theme(plot.title = element_text(hjust = 0.5))
```



Hình 14: Tần số các mức độ béo phì

Phân phối của biểu đồ khá đều, hơi lệch trái nhẹ. Nhóm béo phì tuýp I có số lượng nhiều nhất, kế đó là béo phì tuýp III. Trong khi đó, nhóm thiếu cân được ghi nhận có số lượng nhỏ nhất.


### b) Histogram

```
1 p1_histogram_bmi <- ggplot(Obesity, aes(x = BMI, fill =
2   NObeyesdad)) +
3   geom_histogram(
4     position = "identity",
5     alpha = 0.6,
6     colour = "black"
7   ) +
8   labs(
```

```

8   title = "Histogram của BMI theo NObeyesdad",
9   x = "BMI",
10  y = "Tần số",
11  fill = "Mức độ Béo phì"
12 ) +
13 scale_x_continuous(breaks = seq(15, 50, by = 5)) +
14 theme_classic() +
15 theme(plot.title = element_text(hjust = 0.5))

```



Hình 15: Histogram của BMI theo NObeyesdad

Đồ thị cho thấy phân phối có biên rộng, độ lệch 2 bên nhẹ với khoảng giá trị từ khoảng 12 đến 51. Số lượng người bệnh tập trung cao nhất ở chỉ số BMI  $\approx 27$  (chủ yếu là nhóm thừa cân tuýp I), trong khi nhóm có chỉ số BMI trên 50 có số lượng thấp nhất (nhóm béo phì tuýp III).

c) **Bar plot:** Ta sẽ quan sát mức độ béo phì theo các biến định lượng được đánh giá qua 3 phương diện: thói quen ăn uống, hoạt động đốt cháy calories, và yếu tố khác.

```

1 categorical_vars<-c("Gender","family_history_with_overweight",
2   "FAVC","CAEC","SMOKE",
3   "SCC", "CALC","MTRANS")
4 for (var in categorical_vars) {
5   var_sym <- sym(var)
6
7   p2_barplot <- ggplot(Obesity, aes(x = !!var_sym, fill =
8     NObeyesdad_group)) +
9     geom_bar(position = "fill", color = "black") +
10    scale_y_continuous(labels = scales::percent) +
11    labs(title = paste("Tỉ lệ NObeyesdad theo", var),
12      x = var,
13      y = "Tỉ lệ (%)",


```

```

13     fill = "Nhóm Béo phì") +
14     theme_minimal() +
15     theme(
16       plot.title = element_text(hjust = 0.5),
17       axis.text.x = element_text(angle = 0, hjust = 0.5)
18     )
19 }

```

### Thói quen ăn uống: FAVC, CAEC, CALC




**Hình 16:** Thường xuyên tiêu thụ thức ăn có hàm lượng calo cao (FAVC)

Nhận xét:

- FAVC = 'yes': có tới 50% phân loại yes đến từ nhóm béo phì
- FAVC = 'no': tỉ lệ nhóm ít nguy cơ và thừa cân chiếm ưu thế tuyệt đối (khoảng trên 80%). Tỉ lệ nhóm béo phì rất thấp

**Kết luận:** Nhóm người thường xuyên tiêu thụ thức ăn có hàm lượng calo cao (FAVC = Yes) có khả năng béo phì cao hơn rõ rệt.






**Hình 17:** Thói quen ăn vặt (CAEC)

Nhận xét:

- Nhóm ít nguy cơ có tần suất ăn vặt ở mức cao khi là mode của 2 phân loại ‘Always’, ‘frequently’.
- Nhóm thừa cân có tỉ lệ cao nhất ở tần suất ăn vặt là ‘no’


**Kết luận:** Không có nhiều sự tương quan giữa việc ăn vặt với tỉ lệ đạt béo phì cao. Chúng ta có thể thấy chế độ ăn vặt ở mức cao nhất là ‘always’ nhưng tỉ lệ đóng góp của nhóm normal cao hơn đáng kể so với nhóm béo phì, và sự tăng lên của mức độ thường xuyên ăn vặt không đồng nghĩa với mức độ béo phì tỉ lệ thuận.



**Hình 18:** Tần suất uống đồ có cồn (CALC)

**Kết luận:** tương tự biểu đồ CAEC, chúng ta không nhận thấy sự tương quan giữa việc mắc béo phì với CALC.

**Hoạt động đốt cháy calories:** SCC, MTRANS




**Hình 19:** Có kiểm soát lượng calo hấp thu (SCC)

Nhận xét:

- SCC = 'yes' : nhóm ít nguy cơ chiếm tỉ lệ cao nhất trong khi béo phì có tỉ lệ rất nhỏ khi so cùng.
- SCC = 'no': gần 50% phân loại no là nhóm béo phì

**Kết luận:** Việc ăn uống có kiểm soát lượng calo hấp thu đã giảm thiểu cơ hội béo phì đáng kể.




**Hình 20:** Phương tiện di chuyển chính (MTRANS)

Nhận xét: Nhóm béo phì có tỉ lệ thấp nhất ở đi bộ, tiếp đó là đạp xe


**Kết luận:** Các phương tiện yêu cầu vận động cao như đi bộ, xe đạp có xu hướng ít nguy cơ béo phì hơn.

**Các yếu tố khác:** family\_history\_with\_overweight, SMOKE, gender



**Hình 21:** Giới tính (Gender)

Nhận xét: Nam và nữ có nguy cơ mắc béo phì gần như tương đương nhau. Tuy nhiên, ở nữ, nhóm ít nguy cơ có tỉ lệ thấp hơn ở nam, chênh lệch khoảng 10% .




**Hình 22:** Có tiền sử gia đình bị thừa cân ( family\_ history\_ with\_ overweight)

Nhận xét:

- ‘no’: nhóm normal chiếm tỉ lệ ưu thế khoảng 70%, chênh lệch rõ rệt với nhóm béo phì
- ‘yes’: gần 60% phân loại yes là nhóm béo phì

**Kết luận:** Khi chúng ta tiền sử gia đình bị thừa cân, nguy cơ mắc bệnh béo phì cao hơn rõ rệt so với người không có tiền sử, cho thấy đây là một yếu tố quan trọng để dự đoán nguy cơ béo phì.



**Hình 23:** Có hút thuốc hay không (SMOKE)

Nhận xét: chúng ta không nhận thấy mối liên hệ rõ ràng giữa việc mắc béo phì với hút thuốc.


#### d) Box plot

```

1 for (var in num_vars) {
2   var_sym <- sym(var)
3
4   p3_boxplot <- ggplot(Obesity, aes(x = NObeyesdad_group, y = !
5     !var_sym, fill = NObeyesdad_group)) +
6     geom_boxplot() +
7     labs(title = paste("Boxplot", var, "theo NObeyesdad"),
8          x = "Mức độ béo phì",
9          y = var) +
10    theme_minimal() +
11    theme(plot.title = element_text(hjust = 0.5),
12          legend.position = "none")
13 }

```


## Thói quen ăn uống: CH2O, FCVC, NCP



**Hình 24:** Lượng nước uống mỗi ngày (CH2O)

Nhận xét: Các Boxplot chồng chéo nhau rất nhiều và median của chúng gần nằm sát mức 2 lít/ ngày

**Kết luận:** Uống đủ nước là một thói quen lành mạnh, nhưng chỉ riêng lượng nước uống không đủ để phân biệt người béo phì với người bình thường.




**Hình 25:** Mức độ tiêu thụ rau củ quả (FCVC)

Nhận xét:

- Nhóm Overweight có median thấp nhất ( $\approx 2$ ), cho thấy họ tiêu thụ rau củ quả ít nhất.
- Nhóm Obesity có median cao nhất ( $\approx 2.75$ ), cao hơn cả nhóm Normal.

**Kết luận:** chưa thể kết luận mối liên hệ giữa FCVC và mức độ béo phì. Việc nhóm béo phì có xu hướng tiêu thụ rau củ nhiều nhất có thể đến từ việc họ cố gắng thay đổi thói quen ăn uống




**Hình 26:** Mức độ tiêu thụ rau củ quả (FCVC)

Nhận xét:

- Median giữa các nhóm gần như giống nhau ( $= 3$ )
- Các hộp boxplot rất ngắn, bị nén

**Kết luận:** Phản ánh thói quen ăn uống là 3 bữa/ngày, không có tính phân loại cao với mức độ béo phì

**Hoạt động đốt cháy calo:** FAF, TUE




**Hình 27:** Mức độ hoạt động thể chất hàng ngày (FAF)

Nhận xét:

- Median của FAF có xu hướng giảm khi tình trạng béo phì tăng lên
- Median của nhóm béo phì nhỏ hơn 1

**Kết luận:** 50% số người trong nhóm béo phì có mức độ hoạt động thể chất là chưa tới 1 giờ/ ngày.




**Hình 28:** Thời gian sử dụng thiết bị công nghệ (TUE)

Nhận xét: Các boxplot có sự chồng chéo lớn, median của các nhóm thừa cân và béo phì gần nhau

**Kết luận:** Biểu đồ cho thấy TUE có ảnh hưởng hạn chế và khó dự đoán nguy cơ mắc bệnh


**Các yếu tố khác:** Age, BMI



**Hình 29:** Tuổi (Age)

Nhận xét: Median tăng lên rõ rệt từ nhóm normal đến obesity, boxplot chồng chéo đáng kể

**Kết luận:** tuổi tác là một yếu tố nguy cơ, việc duy trì cân nặng lành mạnh có liên quan đến việc trẻ tuổi hơn trong mẫu.



**Hình 30:** Chỉ số khối cơ thể (BMI)

Nhận xét:


- Median Giá trị median của BMI tăng đều và rõ rệt từ nhóm normal đến obesity.
- Các hộp hầu như không bị chồng chéo, có sự phân tách cao giữa các nhóm
- Nhóm Obesity có giá trị BMI từ 30 đến 52, trung vị khoảng 37, mức phân tán rộng

**Kết luận:** Biểu đồ phản ánh rằng BMI có khả năng phân loại các mức độ béo phì cao, là thước đo cốt lõi để đánh giá mức độ béo phì.

### e) Heat map

```
1 library(corrplot)
2 num_data <- Obesity[, num_vars]
3 cor_matrix <- cor(num_data, use = "complete.obs")
4 round(cor_matrix, 2)
5
6 corrplot(cor_matrix,
7         method = "color",
8         type = "full",
9         addCoef.col = "black",      # thêm hệ số tương quan
10        tl.col = "black",
11        diag = TRUE,
12        tl.srt = 45,
13        title = "Heatmap"
14 )
```





Hình 31

Nhận xét:

- Median BMI và tuổi có tương quan dương mạnh nhất ( 0.29), tiếp đó là FCVC (Mức độ tiêu thụ rau củ quả).
- BMI và FAF (mức độ hoạt động thể chất hàng ngày) có tương quan âm mạnh nhất

**Kết luận:** mức độ hoạt động thể chất hàng ngày cao hơn có liên hệ với mức độ BMI thấp hơn, cho thấy FAF là 1 yếu tố quan trọng chống lại béo phì.

## V Thống kê suy diễn

### 1 Phân tích phương sai một nhân tố

**Bài toán:** Với mức ý nghĩa 5%, chỉ số khối trung bình (BMI) có khác biệt giữa 3 nhóm tình trạng cơ thể ("Normal", "Overweight", và "Obesity") không?


```
1 normal_bmi <- subset(Obesity, NObeyesdad_group == "Normal")$BMI
2 overweight_bmi <- subset(Obesity, NObeyesdad_group == "
  Overweight")$BMI
3 obesity_bmi <- subset(Obesity, NObeyesdad_group == "Obesity")$
  BMI
```

Để thực hiện mô hình phân tích phương sai, ta cần kiểm tra các giả định của mô hình:

- Giả định 1: chỉ số khối trung bình (BMI) ở 3 nhóm tuân theo phân phối chuẩn
- Giả định 2: Phương sai về chỉ số khối trung bình (BMI) ở 3 nhóm là bằng nhau
- Giả định 3: Các quan sát lấy từ mẫu là độc lập với nhau

**Kiểm tra phân phối chuẩn (giả định 1):** Ta sẽ thực hiện kiểm tra các giả định phân phối chuẩn các lệnh `qqnorm()`, `qqline()`, `shapiro.test()`.

```
1 par(mfrow = c(1, 3))
2 qqnorm(normal_bmi, main = "Q-Q Plot: Normal")
3 qqline(normal_bmi)
4 qqnorm(overweight_bmi, main = "Q-Q Plot: Overweight")
5 qqline(overweight_bmi)
6 qqnorm(obesity_bmi, main = "Q-Q Plot: Obesity")
7 qqline(obesity_bmi)
8 par(mfrow = c(1, 1))
```



Hình 32

Hình 32 cho thấy có nhiều điểm quan trắc lệch ra khỏi đường thẳng kỳ vọng phân phối chuẩn ở cả ba đồ thị QQ-plot. Đặc biệt, sự cong ở hai đầu đường thẳng rất rõ rệt. Từ đó, ta dự đoán rằng chỉ số BMI ở ba nhóm ("Normal", "Overweight", và "Obesity") không tuân theo phân phối chuẩn.

Để chắc chắn hơn, ta thực hiện kiểm định Shapiro-Wilk cho BMI trong từng nhóm:

```
1 by(Obesity$BMI, Obesity$NObeyesdad_group, shapiro.test)
```

```
Obesity$NObeyesdad_group: Normal

      Shapiro-Wilk normality test

data:  dd[x, ]
W = 0.91622, p-value < 2.2e-16

-----
Obesity$NObeyesdad_group: Overweight

      Shapiro-Wilk normality test

data:  dd[x, ]
W = 0.97185, p-value = 4.097e-09

-----
Obesity$NObeyesdad_group: Obesity

      Shapiro-Wilk normality test

data:  dd[x, ]
W = 0.95299, p-value < 2.2e-16
```

**Hình 33:** Kết quả kiểm định *shapiro.test* cho biến BMI ở ba nhóm

Giả thuyết cho nhóm "Normal" (Bình thường):

$$\begin{cases} H_0 : \text{Chỉ số BMI ở nhóm "Normal" tuân theo phân phối chuẩn.} \\ H_1 : \text{Chỉ số BMI ở nhóm "Normal" không tuân theo phân phối chuẩn.} \end{cases}$$

Từ kết quả, ta thấy được giá trị  $p\text{-value} < 2.2e-16$  (bé hơn mức ý nghĩa 5%). Đủ cơ sở để bác bỏ  $H_0$ , ta có thể kết luận chỉ số BMI ở nhóm "Normal" không tuân theo phân phối chuẩn.

Giả thuyết cho nhóm "Overweight" (Thừa cân):

$$\begin{cases} H_0 : \text{Chỉ số BMI ở nhóm "Overweight" tuân theo phân phối chuẩn.} \\ H_1 : \text{Chỉ số BMI ở nhóm "Overweight" không tuân theo phân phối chuẩn.} \end{cases}$$

Từ kết quả, ta thấy được giá trị  $p\text{-value} = 4.097e-09$  (bé hơn mức ý nghĩa 5%). Đủ cơ sở để bác bỏ  $H_0$ , ta có thể kết luận chỉ số BMI ở nhóm "Overweight" không tuân theo phân phối chuẩn.

Giả thuyết cho nhóm "Obesity" (Béo phì):

$$\begin{cases} H_0 : \text{Chỉ số BMI ở nhóm "Obesity" tuân theo phân phối chuẩn.} \\ H_1 : \text{Chỉ số BMI ở nhóm "Obesity" không tuân theo phân phối chuẩn.} \end{cases}$$

Từ kết quả, ta thấy được giá trị p-value  $< 2.2e-16$  (bé hơn mức ý nghĩa 5%). Đủ cơ sở để bác bỏ  $H_0$ , ta có thể kết luận chỉ số BMI ở nhóm "Obesity" không tuân theo phân phối chuẩn.

**Kiểm tra phương sai bằng nhau (giả định 2):** Ta thực hiện kiểm tra giả định về phương sai bằng nhau bằng cách sử dụng hàm `leveneTest()`.

```
1 library(car)
2 leveneTest(BMI ~ NObeyesdad_group, data = Obesity)
```

```
Levene's Test for Homogeneity of Variance (center = median)
      Df F value    Pr(>F)
group  2  321.26 < 2.2e-16 ***
      2108
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

**Hình 34:** Kết quả kiểm định kiểm tra giả định về phương sai

Giả thuyết cho bài toán kiểm định trên được phát biểu sau:

$$\begin{cases} H_0 : \sigma_1^2 = \sigma_2^2 = \sigma_3^2 \\ \quad \text{(Phương sai của BMI ở 3 nhóm "Normal", "Overweight", và "Obesity" là bằng nhau)} \\ H_1 : \exists \sigma_i^2 \neq \sigma_j^2 \quad \text{với } i \neq j \\ \quad \text{(Có ít nhất hai nhóm có phương sai BMI khác nhau.)} \end{cases}$$

Ta thấy rằng giá trị p-value ( $\text{Pr}(>F)$ ) là  $< 2.2e-16$ , bé hơn mức ý nghĩa 5%. Đủ cơ sở để bác bỏ  $H_0$ . Vậy nên ta có thể kết luận phương sai BMI ở 3 nhóm tình trạng cơ thể là không bằng nhau (không đồng nhất).

### Kết luận chung về Giả định:

Cả hai giả định quan trọng cho ANOVA đều đã bị vi phạm:

- Dữ liệu BMI trong mỗi nhóm không tuân theo phân phối chuẩn (theo `shapiro.test` ở phần trước).

- Phương sai BMI giữa các nhóm không đồng nhất (theo `leveneTest`).

⇒ Do cả hai giả định đều không được đáp ứng, phân tích phương sai một nhân tố (ANOVA) không phải là phương pháp thống kê phù hợp và kết quả của nó có thể không chính xác. Do đó, quyết định sử dụng kiểm định phi tham số Kruskal-Wallis là hoàn toàn đúng đắn và đáng tin cậy.

Ta tiếp tục thực hiện phân tích phương sai một nhân tố (ANOVA) bằng cách sử dụng lệnh `aov()` và dùng `summary()` để tóm tắt kết quả của mô hình.

```
1 anova_model <- aov(BMI ~ NObeyesdad_group, data = Obesity)
2 summary(anova_model)
```

```

Df Sum Sq Mean Sq F value Pr(>F)
NObeyesdad_group      2 110254    55127   4617 <2e-16 ***
Residuals            2108   25169     12
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

**Hình 35:** Kết quả Phân tích phương sai một nhân tố (ANOVA)

Gọi  $\mu_1, \mu_2, \mu_3$  lần lượt là **BMI trung bình** ở nhóm người "Overweight" (Thừa cân), "Obesity" (Béo phì), "Normal" (Bình thường).

Đặt giả thuyết:

$$\begin{cases} H_0 : \mu_1 = \mu_2 = \mu_3 \\ \text{(BMI trung bình ở 3 nhóm là bằng nhau)} \\ H_1 : \exists \mu_i \neq \mu_j \text{ với } i \neq j \text{ và ít nhất 1 cặp } 1 \leq i, j \leq 3 \\ \text{(Có ít nhất hai nhóm có BMI trung bình là khác nhau)} \end{cases}$$

Vì p-value ( $\Pr(>F)$ )  $\leq 2e-16$  (bé hơn mức ý nghĩa 5%), nên ta bác bỏ giả thuyết  $H_0$ . Vì vậy có sự khác biệt về BMI trung bình giữa 3 nhóm tình trạng cơ thể.

Ngoài ra, ta có thể sử dụng **bảng phân tích phương sai chi tiết** để phân tích:

| Nguồn Biến thiên                            | Bậc tự do     | Tổng chênh lệch bình phương | Trung bình chênh lệch bình phương | Thống kê kiểm định (F value) |
|---------------------------------------------|---------------|-----------------------------|-----------------------------------|------------------------------|
| <b>Giữa các nhóm</b><br>(NObeyesdad_group)  | $df_1 = 2$    | SSB = 110254                | MSB = 55127                       | <b>F = 4617</b>              |
| <b>Trong nội bộ các nhóm</b><br>(Residuals) | $df_2 = 2108$ | SSW = 25169                 | MSW = 12                          |                              |
| <b>Tổng cộng</b>                            | $df = 2110$   | SST = 135423                |                                   |                              |

Ta xác định các giá trị:

- $df_1 = k - 1 = 2 \implies k = 3$  (tức 3 nhóm)
- $df_2 = N - k = 2108 \implies N = 2111$  (tổng số quan sát)
- $R^2 = \frac{SSB}{SST} \times 100\% = \frac{110254}{135423} \times 100\% = 81.41\%$

Hệ số xác định  $R^2$  của mô hình phân tích phương sai được sử dụng để đo mức độ ảnh hưởng của 3 nhóm sức khỏe được xem xét trong mô hình đối với sự biến động 81.41% của các giá trị của BMI quanh giá trị trung bình. Và khi  $R^2$  càng lớn (càng gần 100%) thì mô hình càng thích hợp.

Ta tiếp tục xác định miền bác bỏ:  $RR = (F_{k-1, N-k}; +\infty) = (F_{0.05; 2; 2108}; +\infty)$

Do giá trị N khá lớn, ta sử dụng RStudio để tính toán:

```
1 qf(p = 0.05, df1 = 2, df2 = 2108, lower.tail = FALSE)
```

```
> qf(p = 0.05, df1 = 2, df2 = 2108, lower.tail = FALSE)
[1] 2.999994
```

**Hình 36:** Kết quả

Từ đó, ta xác định miền bác bỏ:  $RR = (2.999994; +\infty)$

Vậy  $F = 4617 \in RR$ , đủ cơ sở để bác bỏ  $H_0$  (giống kết quả khi sử dụng p-value). Vậy ta nói có sự khác biệt về BMI trung bình ở 3 nhóm sức khỏe.

Thực hiện **so sánh bội (Tukey HSD)** để phân tích rõ hơn về sự khác biệt trung bình giữa các nhóm.

```
1 tukey_result <- TukeyHSD(anova_model)
2 tukey_result
```

```
Tukey multiple comparisons of means
95% family-wise confidence level

Fit: aov(formula = BMI ~ NObeyesdad_group, data = Obesity)

$NObeyesdad_group
      diff      lwr      upr p adj
Overweight-Normal  7.331956  6.851619  7.812293    0
Obesity-Normal    17.189117 16.758935 17.619300    0
Obesity-Overweight  9.857161  9.431952 10.282371    0
```

**Hình 37:** Kết quả So sánh Bội (Tukey HSD)

Xét cặp "Overweight - Normal":

$$\begin{cases} H_0 : \mu_1 = \mu_3 \\ H_1 : \mu_1 \neq \mu_3 \end{cases}$$

Dựa vào giá trị  $p - value = 0 < \text{mức ý nghĩa } 5\%$  nên ta đủ cơ sở để bác bỏ giả thuyết  $H_0$ . Vậy  $\mu_1 \neq \mu_3$  (1)

Mức diff =  $x_1 - x_3 = 7.331956 > 0 \Rightarrow x_1 > x_3$  (2)

Từ (1) và (2), ta sẽ có:  $\mu_1 > \mu_3$

Ngoài ra, ta có thể dựa vào khoảng tin cậy (lwr, upr) cho biết sự khác biệt BMI trung bình giữa nhóm Overweight và Normal:  $6.851619 \leq \mu_1 - \mu_3 \leq 7.812293$ . Do khoảng tin cậy không chứa số 0, các giá trị đều là số dương nên ta kết luận  $\mu_1 > \mu_3$

Xét cặp "Obesity - Normal":

$$\begin{cases} H_0 : \mu_2 = \mu_3 \\ H_1 : \mu_2 \neq \mu_3 \end{cases}$$

Dựa vào giá trị p-value = 0 < mức ý nghĩa 5% nên ta đủ cơ sở để bác bỏ giả thuyết  $H_0$ .  
Vậy  $\mu_2 \neq \mu_3$  (3).

Mức diff =  $x_2 - x_3 = 17.189117 > 0 \Rightarrow x_2 > x_3$  (4)

Từ (3) và (4), ta sẽ có:  $\mu_2 > \mu_3$

Ngoài ra, ta có thể dựa vào khoảng tin cậy (lwr, upr) cho biết sự khác biệt BMI trung bình giữa nhóm Overweight và Normal:  $16.758935 \leq \mu_2 - \mu_3 \leq 17.619300$ .

Xét cặp "Obesity - Overweight":

$$\begin{cases} H_0 : \mu_1 = \mu_2 \\ H_1 : \mu_1 \neq \mu_2 \end{cases}$$


Dựa vào giá trị p-value = 0 < mức ý nghĩa 5%, ta đủ cơ sở bác bỏ  $H_0$ . Vậy  $\mu_1 \neq \mu_2$  (5)

Mức diff =  $x_1 - x_2 = 9.857161 > 0 \Rightarrow x_1 > x_2$  (6)

Ngoài ra, ta có thể dựa vào khoảng tin cậy (lwr, upr) cho biết sự khác biệt BMI trung bình giữa nhóm Obesity và Normal:  $9.431952 \leq \mu_1 - \mu_2 \leq 10.282371$ .

Ngoài ra có thể vẽ đồ thị so sánh bội để nhìn trực quan hơn các khoảng tin cậy cho sự khác biệt về trung bình giữa các nhóm:

```
1 plot(TukeyHSD(anova_model))
```



Hình 38

**Kết quả đồ thị so sánh Bội Tukey HSD:** Hình 38 cho ta các khoảng tin cậy có sự khác biệt về độ tuổi trung bình giữa các nhóm. Các cặp "Overweight-Normal", "Obesity-Normal", "Obesity-Overweight" không chứa giá trị 0 nên có thể kết luận có sự khác biệt về BMI trung bình ở 3 nhóm. Từ việc so sánh bội, ta kết luận có sự khác biệt ý nghĩa thống kê về BMI trung bình giữa cả ba nhóm.

**Phân tích Phi tham số (Kruskal-Wallis và Dunn):** Vì dữ liệu vi phạm nghiêm trọng hai giả định về phân phối chuẩn và tính đồng nhất phương sai nên phân tích ANOVA/Tukey ở trên chỉ mang tính tham khảo. Phép kiểm định phi tham số Kruskal-Wallis và kiểm định post-hoc Dunn sau là phương pháp chính xác và đáng tin cậy hơn.

```
1 kruskal.test(BMI ~ NObeyesdad_group, data = Obesity)
```

```
2 dunn.test(Obesity$BMI, Obesity$NObeyesdad_group, method = "
  bonferroni")
```

#### Kết quả Kiểm định Kruskal-Wallis (Tổng thể)

```
> kruskal.test(BMI ~ NObeyesdad_group, data = Obesity)

Kruskal-Wallis rank sum test

data: BMI by NObeyesdad_group
Kruskal-Wallis chi-squared = 1819.9, df = 2, p-value < 2.2e-16
```

#### Kết quả Kiểm định Post-hoc (Dunn's Test)

```
> dunn.test(Obesity$BMI, Obesity$NObeyesdad_group, method = "bonferroni")

Kruskal-Wallis rank sum test

data: x and group
Kruskal-Wallis chi-squared = 1819.9243, df = 2, p-value = 0
```

Comparison of x by group  
(Bonferroni)

| Col      | Mean      | Lower   | Upper    |
|----------|-----------|---------|----------|
| Obesity  | -41.56540 | 0.0000* |          |
| Overweig | -15.73294 | 0.0000* | 24.27884 |

alpha = 0.05  
Reject Ho if p <= alpha/2

Hình 39

**Với Kiểm định Kruskal-Wallis:** Ta nhận kết quả  $p\text{-value} < 2.2e-16$ , bác bỏ giả thuyết  $H_0$ , khẳng định có sự khác biệt về phân bố BMI giữa ít nhất hai trong ba nhóm.

**Với Kiểm định Dunn:** Cho thấy  $p\text{-value}$  (dòng có dấu \*) của cả ba cặp so sánh đều là 0.0000 (nhỏ hơn 0.05).

**Kết luận cuối cùng:** Cả hai phương pháp phân tích (tham số và phi tham số) đều cho cùng một kết luận: có sự khác biệt ý nghĩa thống kê về BMI giữa cả ba nhóm "Normal", "Overweight", và "Obesity". Do dữ liệu vi phạm giả định ANOVA, kết quả từ Kruskal-Wallis và Dunn's Test được coi là kết luận chính thức cho phân tích này.

## 2 Hồi quy Logistic Thứ bậc (Ordinal Logistic Regression)

Để hiểu rõ hơn các yếu tố ảnh hưởng đến tình trạng béo phì, ta cần phân tích và khảo sát các số liệu ảnh hưởng. Một biện pháp phổ biến là sử dụng mô hình hồi quy. Ở phần này, ta sẽ khảo sát biến phân loại NObeyesdad\_group (hay còn gọi là biến phụ thuộc) gồm ba giá trị là "Normal" (Bình thường), "Overweight" (Thừa cân), và "Obesity" (Béo phì).

Mô hình hồi quy sẽ được sử dụng để dự đoán và xác định khả năng một người rơi vào nhóm nào dựa trên các yếu tố nguy cơ như độ tuổi (Age), giới tính (Gender), di truyền (family\_history\_with\_overweight), và các yếu tố lối sống (ví dụ: FAVC, FAF, MTRANS,...). So với phương pháp hồi quy tuyến tính hoặc hồi quy logistic nhị phân, Hồi quy Logistic Thứ bậc (Ordinal Logistic Regression) có sự vượt trội rõ rệt trong việc giải quyết trường hợp này.

Hồi quy tuyến tính được thiết kế cho các biến phụ thuộc là **biến định lượng liên tục**, trong khi biến của chúng ta là **biến định tính thứ bậc**. Cụ thể, nếu sử dụng hồi quy tuyến tính, chúng ta buộc phải mã hóa các nhóm thành các con số thực (ví dụ:



Normal = 1, Overweight = 2, Obesity = 3). Điều này áp đặt một **giả định sai lầm về khoảng cách đều**. Mô hình sẽ mặc định cho rằng sự khác biệt hay "khoảng cách" sinh học từ nhóm Normal (1) lên nhóm Overweight (2) là hoàn toàn tương đương với khoảng cách từ Overweight (2) lên Obesity (3) (vì  $2 - 1 = 3 - 2$ ). Trong thực tế y học và sinh học, các trạng thái này là những phân loại định tính dựa trên các ngưỡng BMI khác nhau, và mức độ nghiêm trọng hay rủi ro sức khỏe giữa các bước chuyển đổi này không hề tuyến tính hay đồng đều. Ngoài ra, mô hình tuyến tính có thể trả về các giá trị dự báo vô nghĩa như 1.5 (không thuộc nhóm nào) hoặc thậm chí là các giá trị nằm ngoài thang đo (ví dụ: 3.5 hoặc -0.5), làm mất đi ý nghĩa phân loại của bài toán.

Tương tự như hồi quy tuyến tính, việc áp dụng Hồi quy Logistic Nhị phân cho bài toán này là không khả thi. Hồi quy logistic nhị phân được thiết kế chuyên biệt cho biến phụ thuộc có tính chất nhị phân, nghĩa là chỉ nhận đúng hai giá trị đối lập (ví dụ: 0/1, Có/Không, Bệnh/Không bệnh). Trong khi đó, biến mục tiêu NObeyesdad\_group của nghiên cứu bao gồm ba nhóm phân loại riêng biệt ("Normal", "Overweight", "Obesity"). Để áp dụng mô hình nhị phân, chúng ta buộc phải thực hiện việc gộp nhóm cưỡng ép – ví dụ: gộp "Overweight" và "Obesity" thành một nhóm "Obesity" để so sánh với nhóm "Normal". Việc làm dẫn đến việc mất mát thông tin nghiêm trọng. Mô hình sẽ không thể phân biệt được sự khác biệt quan trọng giữa một người chỉ mới "Thừa cân" và một người đã bị "Béo phì", đồng thời hoàn toàn bỏ qua cấu trúc thứ bậc của dữ liệu – nơi mà sự chuyển dịch từ nhóm này sang nhóm tiếp theo thể hiện mức độ rủi ro sức khỏe tăng dần.

Mô hình Hồi quy Logistic Thứ bậc được thiết kế để tôn trọng trật tự này, dự đoán khả năng một cá nhân chuyển lên một cấp độ tình trạng cơ thể cao hơn, mang lại kết quả tin cậy và phù hợp với bản chất của dữ liệu hơn.

Để đảm bảo tính chính xác, mô hình trước hết cần được tiền xử lý và sàng lọc để đảm bảo tính chính xác và hiệu quả, việc xử lý đã được thực hiện 1 cách kĩ càng ở phần tiền xử lý dữ liệu, ở đây nhóm sẽ đưa ra những thông tin quan trọng và cần thiết để hỗ trợ cho mô hình:

- Sau khi hoàn tất quá trình làm sạch và xử lý ngoại lai, biến mục tiêu NObeyesdad\_group được xử lý dựa trên biến gốc NObeyesdad. Việc giữ nguyên 7 mức độ chi tiết dễ gây mất cân bằng dữ liệu, hay việc biến nó trở thành bài toán nhị phân (chỉ phân biệt Béo phì/Không béo phì) dễ khiến bài toán trở nên đơn giản quá mức, nhóm nghiên cứu đề tài quyết định phân loại thành 3 mức độ thứ bậc: Normal (Bình thường) < Overweight (Thừa cân) < Obesity (Béo phì). Quyết định này nhằm khắc phục hạn chế của mô hình hồi quy logistic nhị phân là có thể làm mất đi tín hiệu cảnh báo sớm nếu gộp nhóm "Thừa cân" vào "Bình thường", hoặc gây đánh giá sai lệch mức độ nghiêm trọng nếu gộp vào "Béo phì". Việc tách riêng nhóm "Thừa cân" giúp bảo toàn thông tin về giai đoạn chuyển tiếp quan trọng, tạo tiền đề cho các khuyến nghị can thiệp lối sống kịp thời trước khi bệnh tiến triển.

```
1 Obesity$NObeyesdad_group[Obesity$NObeyesdad %in% c("
  Overweight_Level_I", "Overweight_Level_II")] <- "
  Overweight"
2 Obesity$NObeyesdad_group[Obesity$NObeyesdad %in% c("Obesity
  _Type_I", "Obesity_Type_II", "Obesity_Type_III")] <- "
  Obesity"
3 Obesity$NObeyesdad_group[Obesity$NObeyesdad %in% c("
```

```
Insufficient_Weight", "Normal_Weight")] <- "Normal"
4 Obesity$NObeyesdad_group <- factor(Obesity$NObeyesdad_group
  , levels = c("Normal", "Overweight", "Obesity"), ordered =
  TRUE)
```

- Đồng thời mô hình mà nhóm nghiên cứu chọn sẽ loại bỏ biến BMI đã tạo ở trên vì trong model1, biến BMI có sức mạnh dự báo quá lớn (như đã thấy qua chỉ số t-value rất cao). Về mặt thống kê, sự hiện diện của một biến quá mạnh như vậy sẽ ảnh hưởng tiêu cực đến tác động của các biến yếu hơn nhưng quan trọng khác.

Ví dụ: Khi có BMI, các biến như "Tần suất ăn rau"(FCVC) hay "Uống nước"(CH2O) có thể bị mô hình coi là không quan trọng (không có ý nghĩa thống kê) và bị loại bỏ. Khi bỏ BMI (trong Model 2), các biến lối sống này mới có cơ hội bộc lộ rõ mức độ ảnh hưởng của chúng, giúp chúng ta nhìn thấy bức tranh toàn cảnh về các yếu tố nguy cơ.

Trong quá trình xây dựng mô hình dự báo tình trạng cơ thể, dữ liệu được chia thành hai tập: train\_data (dữ liệu huấn luyện) và test\_data (dữ liệu kiểm tra). Train\_data được sử dụng để xây dựng mô hình đồng thời nhằm giúp ước lượng các tham số của mô hình, giúp mô hình học các mối quan hệ giữa các yếu tố nguy cơ và tình trạng béo phì. Test\_data sẽ được dùng để đánh giá hiệu quả của mô hình trên dữ liệu chưa được sử dụng, giúp kiểm tra độ chính xác và khả năng tổng quát của mô hình. Phân chia dữ liệu này giúp tránh tình trạng quá khớp (overfitting) và đảm bảo mô hình hoạt động tốt trên dữ liệu thực tế.

Nhằm đảm bảo kết quả phân tích có thể tái lập chính xác, nhóm đã sử dụng hàm set.seed(100) để khởi tạo quy trình ngẫu nhiên hóa, việc làm này nhằm đảm bảo tính chính xác và ổn định của mô hình khi máy tính lựa chọn dữ liệu theo tiêu chuẩn hàm trên. Dữ liệu sau đó được phân chia bằng hàm createDataPartition() theo phương pháp lấy mẫu ngẫu nhiên thay vì tuần tự. Cách tiếp cận này giúp loại bỏ sự sắp xếp chủ quan ban đầu dựa trên 1 thứ tự nào đó (ví dụ như nếu cắt 70% dòng đầu tiên sẽ khiến cho mô hình chỉ khảo sát phần lớn là người trẻ), đảm bảo các tập dữ liệu con phản ánh đúng đặc trưng của tổng thể, mô hình được học đủ các trường hợp của từng nhóm bệnh, không bị thiên vị nhóm nào, giúp mô hình dự đoán chính xác và công bằng hơn. Hàm trên cũng được tối ưu khi nó nhìn vào biến mục tiêu NObeyesdad\_group. Nếu trong dữ liệu gốc có 20% Normal, 30% Overweight, 50% Obesity. Hàm này sẽ đảm bảo trong tập train cũng có đúng tỷ lệ 20/30/50 đó, và trong tập test cũng có tỷ lệ y hệt.

Dữ liệu được chia thành hai phần: 70% dành cho huấn luyện (train\_data) và 30% dành cho kiểm tra (test\_data)."

```
1 set.seed(100)
2 train_index <- createDataPartition(Obesity$NObeyesdad_group, p
  = 0.7, list = FALSE)
3 train_data <- Obesity[train_index, ]
4 test_data <- Obesity[-train_index, ]
```

|            |                           |
|------------|---------------------------|
| test_data  | 632 obs. of 17 variables  |
| train_data | 1479 obs. of 17 variables |

**Hình 40:** Kết quả của việc phân chia dữ liệu

Nhận xét: Dựa vào kết quả sau khi chia dữ liệu thu thập theo tỉ lệ 70:30 (sử dụng createDataPartition), ta thấy tập huấn luyện (train\_data) có 1479 dòng và 17 cột. Tập kiểm tra (test\_data) chứa 632 dòng và 17 cột.

Ta xây dựng mô hình Hồi quy Logistic Thứ bậc tổng quát, gồm biến phụ thuộc NObeyesdad\_group (với 3 cấp độ có thứ tự: "Normal", "Overweight", "Obesity") và các biến độc lập còn lại trong bộ dữ liệu.

Khác biệt căn bản so với hồi quy logistic nhị phân (vốn chỉ dự báo xác suất của một biến cố đơn lẻ), mô hình hồi quy logistic thứ bậc tập trung vào việc ước lượng xác suất tích lũy (cumulative probability), ký hiệu là  $P(Y \leq j)$ . Chỉ số này biểu thị xác suất để một cá nhân thuộc vào nhóm phân loại thứ  $j$  hoặc các nhóm thấp hơn nó. Cấu trúc toán học của Mô hình Tỷ lệ Chênh Tương xứng (Proportional Odds Model) được biểu diễn như sau:

$$\log \left( \frac{P(Y \leq j)}{1 - P(Y \leq j)} \right) = \alpha_j - (\beta_1 X_1 + \beta_2 X_2 + \dots + \beta_k X_k)$$

- $P(Y \leq j)$  là xác suất tích lũy để biến phụ thuộc  $Y$  rơi vào nhóm  $j$  hoặc thấp hơn.
- $\alpha_j$  là hệ số chặn (ngưỡng cắt) riêng cho từng nhóm  $j$ .
- $\beta_k$  là hệ số hồi quy (giống nhau cho tất cả các nhóm - theo giả định Proportional Odds).

Ta sẽ thực hiện ước lượng các hệ số  $\beta_i$  bằng cách sử dụng lệnh polr() (từ thư viện MASS) với tham số Hess=TRUE (nhằm tính toán sai số chuẩn và t-value). Đồng thời, ta sử dụng lệnh step() để tự động tinh gọn mô hình (chọn các biến có ý nghĩa), việc này giúp mô hình tinh gọn hơn khi mô hình đã tự động loại bỏ các biến Gender, SCC, SMOKE, NCP, lệnh step() thực hiện quy trình lựa chọn biến từng bước (Stepwise Selection) dựa trên chỉ số AIC (Akaike Information Criterion).

- Nguyên lý hoạt động: Hàm này sẽ thử nghiệm bỏ lần lượt từng biến ra khỏi mô hình. Mỗi lần bỏ, nó sẽ tính lại điểm AIC.
- Quy tắc: Nếu bỏ một biến đi mà chỉ số AIC của mô hình giảm xuống (tức là mô hình trở nên tốt hơn, gọn nhẹ hơn), thì nó sẽ loại bỏ vĩnh viễn biến đó.

Và lệnh summary() cho phép xem tóm tắt kết quả mô hình.

```
1 model_full12 <- polr(NObeyesdad_group ~ Gender + Age + family_
  history_with_overweight + FAVC + FCVC + NCP + CAEC + SMOKE +
  CH20 + SCC + FAF + TUE + CALC + MTRANS, data = train_data,
  Hess = TRUE)
2 model12 <- step(model_full12)
```

| Coefficients:                     |         |            |         |
|-----------------------------------|---------|------------|---------|
|                                   | Value   | Std. Error | t value |
| Age                               | 0.1264  | 0.01599    | 7.902   |
| family_history_with_overweightyes | 2.5168  | 0.18067    | 13.931  |
| FAVCyes                           | 1.1258  | 0.19235    | 5.853   |
| FCVC                              | 0.5039  | 0.11270    | 4.471   |
| CAECOften                         | -2.8604 | 0.40751    | -7.019  |
| CAECSometimes                     | 0.3783  | 0.33708    | 1.122   |
| CH2O                              | 0.2612  | 0.10262    | 2.545   |
| FAF                               | -0.3434 | 0.07164    | -4.793  |
| TUE                               | -0.3388 | 0.09932    | -3.411  |
| CALCOften                         | 0.4185  | 0.33544    | 1.248   |
| CALCSometimes                     | 0.3186  | 0.12950    | 2.461   |
| MTRANSOther                       | -0.8334 | 0.39795    | -2.094  |
| MTRANSPublic_Transportation       | 0.8987  | 0.15458    | 5.814   |
| Intercepts:                       |         |            |         |
|                                   | Value   | Std. Error | t value |
| Normal Overweight                 | 6.4543  | 0.6297     | 10.2491 |
| Overweight Obesity                | 8.5429  | 0.6517     | 13.1086 |
| Residual Deviance: 2214.751       |         |            |         |
| AIC: 2244.751                     |         |            |         |

**Hình 41:** Kết quả Tóm tắt Mô hình Hồi quy (Model 2)

Từ hình 41, ta thu được phương trình ước lượng tổng quát (cho phần hệ số) như sau:

$$\log \left( \frac{\hat{P}(Y \leq j)}{1 - \hat{P}(Y \leq j)} \right) = \hat{\alpha}_j - (\hat{\beta}_{\text{Age}} \cdot \text{Age} + \dots + \hat{\beta}_{\text{MTRANS}} \cdot \text{MTRANS})$$

Từ đó, dựa vào bảng dữ liệu, ta thay lần lượt các giá trị Value tương ứng:

$$\begin{aligned} \log \left( \frac{\hat{P}(Y \leq j)}{1 - \hat{P}(Y \leq j)} \right) = & \hat{\alpha}_j - (0.1264 \cdot \text{Age} + 2.5168 \cdot \text{FamilyHistory}_{\text{Yes}} \\ & + 1.1258 \cdot \text{FAVC}_{\text{Yes}} + 0.5039 \cdot \text{FCVC} - 2.8604 \cdot \text{CAEC}_{\text{Often}} \\ & + 0.3783 \cdot \text{CAEC}_{\text{Sometimes}} + 0.2612 \cdot \text{CH2O} - 0.3434 \cdot \text{FAF} \\ & - 0.3388 \cdot \text{TUE} + 0.4185 \cdot \text{CALC}_{\text{Often}} + 0.3186 \cdot \text{CALC}_{\text{Sometimes}} \\ & - 0.8334 \cdot \text{MTRANS}_{\text{Other}} + 0.8987 \cdot \text{MTRANS}_{\text{Public}}) \end{aligned}$$

Trong đó các giá trị  $\hat{\alpha}_j$  (Intercepts) là:

- Với  $j = 1$  (ngưỡng Normal | Overweight):  $\hat{\alpha}_1 = 6.4543$
- Với  $j = 2$  (ngưỡng Overweight | Obesity):  $\hat{\alpha}_2 = 8.5429$

Trong mô hình hồi quy logistic thứ bậc, các giá trị Intercepts đóng vai trò là các ngưỡng cắt để phân chia biến phụ thuộc thành các nhóm thứ tự khác nhau, về mặt toán học, đây là giá trị log-odds tích lũy cơ sở khi các biến độc lập bằng 0. Nếu tổng tác động của các biến giải thích (tuổi, tiền sử gia đình, thói quen ăn uống...) lớn hơn các ngưỡng này, đối tượng sẽ có xu hướng chuyển sang nhóm phân loại cao hơn (từ Bình thường sang Thừa cân sang Béo phì).

Mô hình ước lượng xác suất tích lũy  $P(Y \leq j)$  dựa trên hiệu số giữa ngưỡng cắt alpha mũ  $j$  và sigma bi nhân Xi. Các xác suất cụ thể được tính như sau:

$$P(Y = j | X) = P(Y \leq j | X) - P(Y \leq j - 1 | X)$$

Cụ thể, ta có các công thức tương ứng trong bài do nhóm nghiên cứu tìm hiểu:

- **Nhóm Bình thường (Normal):** Tính trực tiếp dựa trên ngưỡng cắt đầu tiên ( $\hat{\alpha}_1$ ):

$$P(\text{Normal}) = P(Y \leq \text{Normal}) = \frac{e^{\hat{\alpha}_1 - \sum \hat{\beta}_i X_i}}{1 + e^{\hat{\alpha}_1 - \sum \hat{\beta}_i X_i}}$$

- **Nhóm Thừa cân (Overweight):** Được xác định bằng hiệu số giữa xác suất tích lũy tại ngưỡng 2 và ngưỡng 1:

$$P(\text{Overweight}) = P(Y \leq \text{Overweight}) - P(Y \leq \text{Normal})$$

Cụ thể:

$$P(\text{Overweight}) = \left( \frac{e^{\hat{\alpha}_2 - \sum \hat{\beta}_i X_i}}{1 + e^{\hat{\alpha}_2 - \sum \hat{\beta}_i X_i}} \right) - \left( \frac{e^{\hat{\alpha}_1 - \sum \hat{\beta}_i X_i}}{1 + e^{\hat{\alpha}_1 - \sum \hat{\beta}_i X_i}} \right)$$

- **Nhóm Béo phì (Obesity):** Là phần xác suất còn lại:

$$P(\text{Obesity}) = 1 - P(Y \leq \text{Overweight}) = 1 - \frac{e^{\hat{\alpha}_2 - \sum \hat{\beta}_i X_i}}{1 + e^{\hat{\alpha}_2 - \sum \hat{\beta}_i X_i}}$$

**Thực hiện kiểm định hệ số  $\beta_i$  với giả thuyết:**

$$\begin{cases} H_0 : \beta_i = 0 & \text{với } i \in \{1, 2, 3, \dots, 13\} \text{ (Biến thứ } i \text{ không ảnh hưởng đến biến mục tiêu đề bài)} \\ H_1 : \beta_i \neq 0 & \text{với } i \in \{1, 2, 3, \dots, 13\} \text{ (Biến thứ } i \text{ ảnh hưởng đến biến mục tiêu đề bài)} \end{cases}$$

Dựa vào kết quả cột **t value**, ta sử dụng quy tắc: nếu giá trị tuyệt đối  $|t \text{ value}| > 1.96$  (tương đương  $p\text{-value} < 0.05$ ), ta có đủ cơ sở để bác bỏ giả thuyết  $H_0$ .

Ta nhận thấy tất cả các biến trong Bảng 40 (đã được step() tinh gọn) đều có giá trị  $|t \text{ value}| > 1.96$ . Ví dụ: family\_history\_with\_overweight<sub>yes</sub> ( $|13.931| > 1.96$ ), FAF ( $|-4.793| > 1.96$ ), .... Vậy ta bác bỏ giả thuyết  $H_0$  cho tất cả các biến này. Hay nói cách khác, các biến Age, family\_history\_with\_overweight, FAVC, FCVC, CAEC, CH2O, FAF, TUE, CALC, và MTRANS đều có ảnh hưởng có ý nghĩa thống kê đến việc dự báo tình trạng béo phì.

Ta nhận thấy tất cả các biến được giữ lại trong mô hình model2 (sau khi đã được step() tinh gọn) đều có giá trị  $|t \text{ value}| > 1.96$ . (Ví dụ: family\_history\_with\_overweight<sub>yes</sub> có  $t = 11.874$ , FAF có  $t = -8.923$ , GenderMale có  $t = 3.470$ ). Vậy ta có đủ cơ sở để bác bỏ giả thuyết  $H_0$  cho tất cả các biến này. Hay nói cách khác, các biến Age, family\_history\_with\_overweight, FAVC, FCVC, CAEC, CH2O, FAF, TUE, CALC, và MTRANS đều có ảnh hưởng có ý nghĩa thống kê đến việc dự báo tình trạng béo phì.

Bên cạnh các ước lượng về hệ số hồi quy, bảng kết quả còn cung cấp các chỉ số quan trọng để đánh giá độ phù hợp tổng quát của mô hình:

- **Độ lệch dư (Residual Deviance):** Chỉ số này phản ánh sự chênh lệch giữa mô hình ước lượng và dữ liệu thực tế (thông qua hàm log-likelihood). Giá trị Residual Deviance càng nhỏ chứng tỏ mô hình càng mô tả sát với dữ liệu quan sát được. Với giá trị 2214.751, chỉ số này cho thấy mức độ sai số còn lại sau khi đã đưa các biến độc lập vào mô hình.



- **Tiêu chí thông tin Akaike (AIC):** Đây là thước đo tiêu chuẩn để so sánh và lựa chọn mô hình tối ưu. AIC đánh giá chất lượng mô hình dựa trên sự cân bằng (trade-off) giữa độ tương thích với dữ liệu và độ phức tạp của mô hình (số lượng biến số). Một mô hình tốt là mô hình có AIC thấp nhất, tức là giải thích dữ liệu tốt nhất với số lượng biến tối thiểu để tránh hiện tượng quá khớp (overfitting).

*Dáng chú ý*, giá trị AIC 2244.751 là kết quả cuối cùng của quá trình chọn lọc biến từng bước (stepwise selection) bằng hàm step(). Thuật toán này đã tự động loại bỏ các biến không đóng góp ý nghĩa thống kê, đảm bảo đây là cấu trúc mô hình tinh gọn và hiệu quả nhất."

### Phân tích Mô hình Hồi quy Tối ưu (Model 2)

Sau khi kiểm định các hệ số của mô hình tổng quát, ta thấy rằng mô hình model2 (sau khi đã step()) là mô hình tối ưu để phân tích các yếu tố lối sống.

| Coefficients:                     |         |            |         |
|-----------------------------------|---------|------------|---------|
|                                   | Value   | Std. Error | t value |
| Age                               | 0.1264  | 0.01599    | 7.902   |
| family_history_with_overweightyes | 2.5168  | 0.18067    | 13.931  |
| FAVCyes                           | 1.1258  | 0.19235    | 5.853   |
| FCVC                              | 0.5039  | 0.11270    | 4.471   |
| CAECOfren                         | -2.8604 | 0.40751    | -7.019  |
| CAECSometimes                     | 0.3783  | 0.33708    | 1.122   |
| CH2O                              | 0.2612  | 0.10262    | 2.545   |
| FAF                               | -0.3434 | 0.07164    | -4.793  |
| TUE                               | -0.3388 | 0.09932    | -3.411  |
| CALCOften                         | 0.4185  | 0.33544    | 1.248   |
| CALCSometimes                     | 0.3186  | 0.12950    | 2.461   |
| MTRANSOther                       | -0.8334 | 0.39795    | -2.094  |
| MTRANSPublic_Transportation       | 0.8987  | 0.15458    | 5.814   |
| Intercepts:                       |         |            |         |
|                                   | Value   | Std. Error | t value |
| Normal Overweight                 | 6.4543  | 0.6297     | 10.2491 |
| Overweight Obesity                | 8.5429  | 0.6517     | 13.1086 |
| Residual Deviance: 2214.751       |         |            |         |
| AIC: 2244.751                     |         |            |         |

**Hình 42:** Kết quả Tóm tắt Mô hình Hồi quy Logistic Thứ bậc (Model 2)

### Nhận xét:

- Với biến định lượng (Biến Age): Hệ số hồi quy của Age là 0.1264 (Dương).
  - Hệ số hồi quy của biến Age là  $\hat{\beta} = 0.1264$ . Điều này cho biết rằng khi tuổi tăng thêm 1 năm (trong điều kiện giữ nguyên các yếu tố khác), log-odds của việc rơi vào nhóm cân nặng cao hơn (từ Bình thường lên Thừa cân, hoặc từ Thừa cân lên Béo phì) sẽ tăng thêm 0.1264 đơn vị.
  - **Ý nghĩa thực tế:** Tuổi tác có tác động tích cực đến khả năng tăng cân; người càng lớn tuổi thì nguy cơ đối mặt với tình trạng thừa cân và béo phì càng cao.
- Với biến định tính (Biến Family\_history\_with\_overweight): Hệ số của nhóm "Yes" là 2.5168 (Dương và có giá trị lớn nhất trong các biến).
  - Hệ số của biến tiền sử gia đình là  $\hat{\beta} = 2.5168$ . Kết quả này chỉ ra rằng những người có thành viên gia đình bị thừa cân (nhóm Yes) có log-odds rơi vào mức độ béo phì cao hơn tăng thêm tới 2.5168 đơn vị so với những người không có tiền sử gia đình (nhóm No).

- **Ý nghĩa thực tế:** Yếu tố di truyền hoặc môi trường sinh hoạt chung của gia đình là tác nhân mạnh mẽ nhất thúc đẩy tình trạng béo phì trong mô hình này.

3. Với biến có hệ số Âm (Biến FAF - Tần suất vận động thể chất): Hệ số của FAF là -0.3434 (Âm).

- Hệ số của biến Tần suất hoạt động thể chất (FAF) là  $\beta = -0.3434$ . Điều này cho thấy mối quan hệ nghịch biến: khi tần suất vận động tăng lên, log-odds của việc rơi vào các nhóm cân nặng cao (béo phì) sẽ giảm đi 0.3434 đơn vị.
- **Ý nghĩa thực tế:** Chế độ vận động đóng vai trò kìm hãm sự tăng cân; người vận động càng thường xuyên thì khả năng bị béo phì càng thấp.

```
Call:
polr(formula = NObeyesdad_group ~ Gender + Age + FAVC + FCVC +
      CAEC + SMOKE + SCC + BMI, data = train_data, Hess = TRUE)
```

Coefficients:

|               | Value   | Std. Error | t value  |
|---------------|---------|------------|----------|
| GenderMale    | -2.5512 | 0.9847     | -2.59086 |
| Age           | 0.1804  | 0.1038     | 1.73864  |
| FAVCyes       | 3.0056  | 1.2428     | 2.41846  |
| FCVC          | -2.2535 | 0.9645     | -2.33645 |
| CAECOften     | -0.1675 | 12.5857    | -0.01331 |
| CAECSometimes | 3.4324  | 12.5916    | 0.27260  |
| SMOKEyes      | -2.3684 | 1.7820     | -1.32904 |
| SCCYes        | 6.3890  | 2.8130     | 2.27122  |
| BMI           | 8.2824  | 1.5631     | 5.29876  |

Intercepts:

|                    | Value    | Std. Error | t value |
|--------------------|----------|------------|---------|
| Normal Overweight  | 208.7852 | 41.6072    | 5.0180  |
| Overweight Obesity | 251.9835 | 49.3496    | 5.1061  |

Residual Deviance: 44.02241  
AIC: 66.02241

**Hình 43:** Kết quả Tóm tắt Mô hình Hồi quy Logistic Thứ bậc (Model 1) nhằm tham khảo

### Đánh giá Mô hình trên Tập Kiểm tra (Test Set)

Ta thực hiện dự báo trên tập test\_data bằng cách sử dụng model2. Ta sử dụng lệnh predict() để trả về nhóm được dự đoán. Các giá trị này được thêm vào cột mới tên là predicted\_value. Ta dùng lệnh head() in kết quả 10 dòng đầu tiên để kiểm tra kết quả dự đoán.

```
1 # Dự báo class cho Model 2
2 pred_class2 <- predict(model2, newdata = test_data)
3
4 # Thêm cột dự đoán vào test_data
5 test_data_with_pred <- test_data
6 test_data_with_pred$predicted_value <- pred_class2
7
8 # Hiển thị 10 dòng đầu tiên
9 head(test_data_with_pred, 10)
```

|    | Gender | Age | family_history_with_overweight | FAVC                | FCVC       | NCP | CAEC             | SMOKE     | CH2O | SCC             | FAF | TUE | CALC |           |
|----|--------|-----|--------------------------------|---------------------|------------|-----|------------------|-----------|------|-----------------|-----|-----|------|-----------|
| 4  | Male   | 27  |                                | no                  | no         | 3   | 3                | Sometimes | no   | 2               | no  | 2   | 0    | Often     |
| 7  | Female | 23  |                                | yes                 | yes        | 3   | 3                | Sometimes | no   | 2               | no  | 1   | 0    | Sometimes |
| 10 | Male   | 22  |                                | yes                 | yes        | 2   | 3                | Sometimes | no   | 2               | no  | 1   | 1    | no        |
| 12 | Female | 21  |                                | yes                 | yes        | 2   | 3                | Often     | no   | 2               | yes | 2   | 1    | Sometimes |
| 14 | Male   | 23  |                                | no                  | yes        | 2   | 3                | Sometimes | no   | 2               | no  | 2   | 1    | Often     |
| 15 | Male   | 23  |                                | yes                 | yes        | 3   | 1                | Sometimes | no   | 1               | no  | 1   | 1    | Sometimes |
| 19 | Female | 30  |                                | yes                 | yes        | 3   | 4                | Often     | yes  | 1               | no  | 0   | 0    | no        |
| 21 | Male   | 22  |                                | yes                 | no         | 2   | 3                | Sometimes | no   | 2               | no  | 3   | 2    | no        |
| 22 | Female | 23  |                                | yes                 | yes        | 3   | 1                | Sometimes | yes  | 2               | no  | 0   | 0    | no        |
| 30 | Male   | 23  |                                | no                  | yes        | 2   | 3                | Sometimes | no   | 2               | no  | 2   | 2    | Often     |
|    |        |     | MTRANS                         |                     | NObeyesdad | BMI | NObeyesdad_group |           |      | predicted_value |     |     |      |           |
| 4  |        |     | Other                          | Overweight_Level_I  | 26.85      | 185 | Overweight       |           |      | Normal          |     |     |      |           |
| 7  |        |     | Other                          | Normal_Weight       | 24.44      | 444 | Normal           |           |      | Overweight      |     |     |      |           |
| 10 |        |     | Public_Transportation          | Normal_Weight       | 22.98      | 540 | Normal           |           |      | Obesity         |     |     |      |           |
| 12 |        |     | Public_Transportation          | Overweight_Level_II | 27.04      | 164 | Overweight       |           |      | Normal          |     |     |      |           |

**Hình 44:** Kết quả thực hiện dự báo 10 dòng đầu từ tập `test_data` (Kết quả hiển thị có thể khác nhau tùy vào `set.seed`)

**Nhận xét:** Kết quả cho thấy 10 quan sát ở cột predicted\_value (dự đoán) và cột NObayesdad\_group (thực tế). Ví dụ, ở dòng 10, mô hình dự đoán chính xác "Normal". Ở dòng 2, mô hình dự đoán sai ("Overweight" trong khi thực tế là "Normal").

Với số lượng 10 quan sát này chưa đủ để đánh giá toàn diện. Do đó, ta sẽ tạo Ma trận Nhầm lẫn (Confusion Matrix) nhằm thể hiện số lượng quan sát mà mô hình hồi quy logistic phân loại đúng hoặc sai so với giá trị thực tế.

```
1 conf_mat2 <- confusionMatrix(pred_class, test_data$NObeyesdad_
  group)
2 conf_mat2
```

### Confusion Matrix and Statistics

|            | Reference |            |         |
|------------|-----------|------------|---------|
| Prediction | Normal    | Overweight | Obesity |
| Normal     | 116       | 41         | 9       |
| Overweight | 32        | 33         | 26      |
| Obesity    | 19        | 100        | 256     |

## Overall Statistics

Accuracy : 0.6408  
95% CI : (0.602, 0.6783)  
No Information Rate : 0.4604  
P-Value [Acc > NIR] : < 2.2e-16

Kappa : 0.4186

McNemar's Test P-Value : 1.987e-10

### Statistics by Class:

|                      | Class: Normal | Class: Overweight | Class: Obesity |
|----------------------|---------------|-------------------|----------------|
| Sensitivity          | 0.6946        | 0.18966           | 0.8797         |
| Specificity          | 0.8925        | 0.87336           | 0.6510         |
| Pos Pred Value       | 0.6988        | 0.36264           | 0.6827         |
| Neg Pred Value       | 0.8906        | 0.73937           | 0.8638         |
| Prevalence           | 0.2642        | 0.27532           | 0.4604         |
| Detection Rate       | 0.1835        | 0.05222           | 0.4051         |
| Detection Prevalence | 0.2627        | 0.14399           | 0.5934         |
| Balanced Accuracy    | 0.7935        | 0.53151           | 0.7654         |

**Hình 45:** *Kết quả Ma trận Nhầm lẫn*



Ma trận cho thấy:

- 116 trường hợp "Normal" được dự đoán chính xác.
- 33 trường hợp "Overweight" được dự đoán chính xác.
- 256 trường hợp "Obesity" được dự đoán chính xác.
- Trong đó, sai lầm lớn nhất đó là: 100 trường hợp "Overweight" bị dự đoán sai thành "Obesity".

**Accuracy** =  $(116 + 33 + 256) / (116 + 41 + 9 + 32 + 33 + 26 + 19 + 100 + 256) = 0.6408$  Với hệ số Accuracy = 0.6408 (hay 64.08%), cho thấy mô hình có khả năng dự đoán đúng khá tốt (cao hơn mức đoán mò là 46.04%).

**Độ nhạy (Sensitivity)** cho thấy tỉ lệ mô hình phát hiện đúng trong từng nhóm:

- Sensitivity(Normal) =  $116 / (32 + 19 + 116) = 0.6946$  (69.5%)
- Sensitivity(Overweight) =  $33 / (33 + 41 + 100) = 0.1897$  (19.0%)
- Sensitivity(Obesity) =  $256 / (256 + 9 + 26) = 0.8797$  (88.0%)


Độ nhạy của nhóm "Overweight" rất thấp (19.0%), cho thấy mô hình rất yếu trong việc nhận diện nhóm này.

**Độ đặc hiệu (Specificity)** cho thấy khả năng mô hình xác định đúng các trường hợp không thuộc nhóm đó:

- Specificity(Normal) =  $(33 + 26 + 100 + 256) / (41 + 9 + 33 + 26 + 100 + 256) = 0.8925$  (89.3%)
- Specificity(Overweight) =  $(116 + 9 + 19 + 256) / (116 + 9 + 32 + 26 + 19 + 256) = 0.8734 = 0.8734$  (87.3%)
- Specificity(Obesity) =  $(116 + 41 + 32 + 33) / (116 + 41 + 32 + 33 + 9 + 26) = 0.6510$  (65.1%)

Độ đặc hiệu của các nhóm đều ở mức khá, cho thấy mô hình hoạt động tương đối tốt trong việc loại trừ.

Ngoài ra còn có thể đánh giá mô hình bằng đồ thị ROC - chỉ số AUC:



Hình 46

Từ các đồ thị ROC và các chỉ số AUC tương ứng, cho thấy mô hình hồi quy logistic thứ bậc có khả năng phân biệt khác nhau đối với từng nhóm như sau:

- Khả năng phân biệt nhóm "Obesity"(Béo phì) so với các nhóm còn lại là rất tốt (với AUC dự kiến  $> 0.85$ ).
- Khả năng phân biệt nhóm "Normal"(Bình thường) là rất tốt (với AUC dự kiến  $> 0.9$ ).
- Khả năng phân biệt nhóm "Overweight"(Thừa cân) là rất thấp (với AUC dự kiến chỉ khoảng 0.55-0.63), điều này nhất quán với chỉ số Độ nhạy (Sensitivity) thấp đã thấy trong Ma trận Nhầm lẫn mà nhóm đã trình bày phiên trên

Để đánh giá mức mô hình Hồi quy Logistic Thứ bậc (polr) có hoạt động hiệu quả và đáng tin cậy không, ta tiến hành kiểm tra các điều kiện (giả định) quan trọng của mô hình này như sau:

- Biến phụ thuộc (NObesidad\_group) là biến thứ bậc (ordinal), (điều kiện này thỏa mãn với 3 giá trị "Normal"  $<$  "Overweight"  $<$  "Obesity").
- Không có hiện tượng đa cộng tuyến giữa các biến độc lập
- Mỗi quan hệ giữa các biến giải thích (independent variables) và log-odds (hay logit(P)) phải là tuyến tính.
- Sai số độc lập.
- Tỷ lệ chênh tương xứng
- Cỡ mẫu lớn

**Kiểm tra hiện tượng đa cộng tuyến bằng chỉ số VIF**

Hiện tượng đa cộng tuyến (Multicollinearity) xảy ra khi các biến độc lập trong mô hình có mối tương quan cao, gây ảnh hưởng đến độ ổn định của ước lượng hồi quy. Để kiểm tra đa cộng tuyến, ta sử dụng chỉ số VIF.

```
1 library(car)
2
3 vif_check_model <- lm(Age ~ Gender + family_history_with_
  overweight + FAVC + FCVC + NCP + CAEC + SMOKE + CH20 + SCC +
  FAF + TUE + CALC + MTRANS, data = train_data)
4
5 vif(vif_check_model)
```

|                                | GVIF     | Df | GVIF <sup>1/(2*Df)</sup> |
|--------------------------------|----------|----|--------------------------|
| Gender                         | 1.221121 | 1  | 1.105044                 |
| family_history_with_overweight | 1.295514 | 1  | 1.138206                 |
| FAVC                           | 1.132898 | 1  | 1.064377                 |
| FCVC                           | 1.156911 | 1  | 1.075598                 |
| NCP                            | 1.081378 | 1  | 1.039893                 |
| CAEC                           | 1.358298 | 2  | 1.079565                 |
| SMOKE                          | 1.036522 | 1  | 1.018097                 |
| CH20                           | 1.164633 | 1  | 1.079182                 |
| SCC                            | 1.098100 | 1  | 1.047903                 |
| FAF                            | 1.148814 | 1  | 1.071827                 |
| TUE                            | 1.097920 | 1  | 1.047817                 |
| CALC                           | 1.174670 | 2  | 1.041068                 |
| MTRANS                         | 1.157042 | 2  | 1.037140                 |

**Hình 47:** Kết quả chỉ số VIF (Hệ số Phóng đại Phương sai)

Để hiểu bảng dữ liệu, chúng ta cần định nghĩa 3 cột thông tin chính:

- **GVIF** (Generalized Variance Inflation Factor - Hệ số phóng đại phương sai tổng quát): Đây là chỉ số đo lường mức độ mà phương sai của hệ số hồi quy bị tăng lên do sự tương quan giữa biến đó với các biến độc lập khác trong mô hình. Giá trị càng cao, hiện tượng đa cộng tuyến càng nghiêm trọng. **Lưu ý:** GVIF là phiên bản mở rộng của VIF, được thiết kế đặc biệt cho các mô hình có chứa biến định tính (categorical variables) hoặc biến giả (dummy variables).
- **Df** (Degrees of Freedom - Bậc tự do): Số lượng hệ số hồi quy liên quan đến biến đó.
  - Với biến định lượng (như Age, NCP): Df = 1.
  - Với biến định tính có k nhóm (như MTRANS, CAEC): Df = k-1. (Ví dụ MTRANS có Df= 2 nghĩa là biến này có 3 nhóm giá trị, được tách thành 2 biến giả trong mô hình).
- **$GVIF^{\frac{1}{2 \times Df}}$**  (Adjusted GVIF - GVIF điều chỉnh): Đây là chỉ số quan trọng nhất để so sánh. Vì GVIF phụ thuộc vào số bậc tự do (Df), nên chúng ta không thể so sánh trực tiếp GVIF của biến có Df=1 với biến có Df=2. Chỉ số này đưa tất cả về cùng một mặt bằng chung, phản ánh mức độ phóng đại của Sai số chuẩn (Standard Error) chứ không phải Phương sai.

Với **VIF truyền thống** ta chỉ tính toán cho từng hệ số riêng lẻ (từng biến giả tách rời). Ví dụ: Biến MTRANS (Phương tiện) chia thành MTRANS\_Car và MTRANS\_Bike. VIF sẽ tính độ tương quan giữa Car và Bike. Tuy nhiên, về mặt logic, nếu bạn đi xe hơi thì bạn không đi xe đạp, nên chúng luôn có tương quan với nhau. Dùng VIF thường sẽ báo động giả (False Positive) về đa cộng tuyến giữa các nhóm của cùng một biến.

Với **GVIF**: Xem xét toàn bộ biến MTRANS (gồm tất cả các nhóm con của nó) như một khối thống nhất để tính toán độ tương quan với các biến khác (như Age, Gender). Do đó, GVIF chính xác hơn khi mô hình có các biến phân loại nhiều nhóm (Polytomous variables).

Để đánh giá, ta so sánh giá trị ở cột  $GVIF^{1/(2 \cdot Df)}$ :

- **Quy tắc ngón tay cái (Rule of thumb):**

- Nếu dùng VIF chuẩn:  $VIF < 5$  (hoặc 10) là an toàn.
- Nếu dùng GVIF điều chỉnh: Giá trị này tương đương với  $\sqrt{VIF}$ . Do đó, ngưỡng an toàn là  $< \sqrt{5} \approx 2.24$ .
- Nếu giá trị này **gần bằng 1**, nghĩa là hoàn toàn không có đa cộng tuyến.

- **Phân tích cụ thể:**

- Nhìn vào cột thứ 3 ( $GVIF^{1/(2 \cdot Df)}$ ), tất cả các giá trị đều cực kỳ thấp, dao động từ 1.01 đến 1.13.
- Giá trị cao nhất là family\_history\_with\_overweight (1.138) và Gender (1.105). Tuy nhiên, mức 1.13 vẫn thấp hơn rất nhiều so với ngưỡng cảnh báo (2.24).
- Các biến như SMOKE, NCP, MTRANS có giá trị xấp xỉ 1.0, cho thấy chúng gần như độc lập hoàn toàn với các biến còn lại.

Kiểm định đa cộng tuyến được thực hiện bằng phương pháp Hệ số phóng đại phương sai tổng quát (GVIF) do mô hình có chứa nhiều biến định tính. Kết quả cho thấy các giá trị GVIF điều chỉnh ( $GVIF^{1/(2 \cdot Df)}$ ) của tất cả các biến đều rất thấp, nằm trong khoảng từ 1.01 đến 1.14, thấp hơn rất nhiều so với ngưỡng cảnh báo thường dùng là 2.24 (tương đương  $\sqrt{VIF} < \sqrt{5}$ ).

**Kết luận:** Không xảy ra hiện tượng đa cộng tuyến giữa các biến độc lập trong mô hình. Các biến số hoàn toàn đủ điều kiện để đưa vào phân tích hồi quy.

Kiểm tra mối quan hệ giữa tuyến tính giữa các biến giải thích (independent variables) và log-odds (hay logit(P))


Mục đích của kiểm định này là để đảm bảo độ tin cậy của các hệ số hồi quy (beta). Mô hình Logistic giả định rằng tác động của biến độc lập lên log-odds là không đổi (tuyến tính) trên toàn bộ miền giá trị. Nếu giả định này thỏa mãn, ta có thể tự tin kết luận rằng sự thay đổi của biến giải thích sẽ dẫn đến sự thay đổi tương ứng và nhất quán của log-odds về tình trạng béo phì.

```
1 probs_train <- predict(model2, type = "probs")
2 prob_normal <- probs_train[, "Normal"]
3 log_odds_normal <- log(prob_normal / (1 - prob_normal))
```

```

4 par(mar = c(4, 4, 2, 1))
5 plot(train_data$Age, log_odds_normal,
6      main = "Mối quan hệ giữa Age và Log-odds (Normal vs Others)",
7      xlab = "Age (Tuổi)",
8      ylab = "Log-odds của xác suất thuộc nhóm Normal",
9      pch = 19, col = "blue", cex = 0.6) # Trang trí cho đẹp hơn
10
11 lines(lowess(train_data$Age, log_odds_normal), col = "red", lwd
12       = 2)

```



Hình 48

Trước khi đi vào phân tích biểu đồ, ta cần làm rõ hai khái niệm nền tảng:

**Log-odds (Logit):** Là logarit tự nhiên của tỷ lệ cược (odds). Trong ngữ cảnh của biểu đồ này, trục tung thể hiện Log-odds của xác suất thuộc nhóm Normal (nhóm cân nặng Bình thường).

**Giả định Tuyến tính (Linearity Assumption):** Hồi quy Logistic yêu cầu mối quan hệ giữa biến độc lập liên tục (Age) và Log-odds của biến phụ thuộc phải là một đường thẳng (tuyến tính). Nghĩa là, khi tuổi tăng lên một đơn vị, log-odds sẽ thay đổi một lượng không đổi, bất kể đang ở độ tuổi nào.

**Đối với xu hướng chung (Đường màu đỏ):** Đường màu đỏ (đường xu hướng làm trơn - smoothed trend line) thể hiện mối quan hệ thực tế giữa dữ liệu:

- **Giai đoạn từ 14 đến khoảng 25 tuổi:** Đường màu đỏ có xu hướng dốc xuống khá thẳng. Điều này cho thấy khi tuổi tăng, log-odds (khả năng thuộc nhóm "Normal") giảm đi một cách tuyến tính. Điều này hoàn toàn phù hợp với hệ số hồi quy dương  $\beta_{Age} = 0.1264$  đã tính ở phần trước (vì khả năng thuộc nhóm "Normal" giảm đi đồng nghĩa với nguy cơ thuộc nhóm "Thừa cân/Béo phì" tăng lên).

- **Giai đoạn từ 26 đến 35 tuổi:** Đường xu hướng bắt đầu đi ngang (bão hòa). Ở độ tuổi này, sự gia tăng của tuổi không còn làm giảm mạnh khả năng thuộc nhóm Normal nữa mà giữ ở mức thấp ổn định.

### **Đánh giá tính tuyến tính:**

- Mặc dù có sự thay đổi độ dốc nhẹ sau ngưỡng 25 tuổi, nhưng nhìn tổng thể trên toàn bộ dải dữ liệu, đường xu hướng không hiển thị các hình dạng phi tuyến phức tạp (như hình chữ U hay hình Sin).
- Đoạn dốc xuống chiếm phần lớn mật độ dữ liệu quan trọng, thể hiện rõ mối quan hệ tỷ lệ nghịch giữa Tuổi và khả năng giữ dáng (Normal).

### **Nhận xét:**

- Biểu đồ cho thấy đường xu hướng thực nghiệm (đường màu đỏ) có độ dốc âm rõ rệt, phản ánh đúng bản chất của hệ số hồi quy: tuổi càng cao, xác suất duy trì ở nhóm cân nặng 'Bình thường' (Normal) càng giảm (tương đương với việc nguy cơ béo phì tăng lên).
- Mặc dù xuất hiện hiện tượng bão hòa nhẹ sau độ tuổi 25, nhưng xét trên tổng thể, mối quan hệ này vẫn mang tính chất đơn điệu (monotonic) và tiệm cận với đường thẳng. Không có bằng chứng về sự vi phạm nghiêm trọng giả định tuyến tính (như đường cong đảo chiều). Do đó, việc sử dụng biến Age dưới dạng tuyến tính trong mô hình là chấp nhận được và phản ánh đúng xu hướng chính của dữ liệu."

Đồng thời, việc đường màu đỏ đi xuống (Negative slope) trong biểu đồ này khớp hoàn toàn với hệ số dương (Positive coefficient) của Age trong bảng số liệu trước đó. Trục Y là Log-odds của normal khi đi xuống tương đương với khả năng normal giảm. Với mô hình dự báo nguy cơ Béo phì thì hệ số dương tương đương với nguy cơ béo phì tăng. Hai điều trên tương đương với nhau.

**Kiểm tra mô hình có sai số độc lập:** Trong phân tích hồi quy, việc giả định về độ độc lập của sai số (independence of errors) là vô cùng cần thiết để đảm bảo tính đúng đắn của mô hình. Điều này có thể được kiểm tra bằng kiểm định Durbin-Watson.

```
1 dw_check_model <- lm(as.numeric(NObeyesdad_group) ~ Age +
  family_history_with_overweight + FAVC + FCVC + NCP + CAEC +
  CH20 + FAF + TUE + CALC + MTRANS, data = train_data)
2 dw_result <- dwtest(dw_check_model)
```

#### **Durbin-Watson test**

```
data: dw_check_model
DW = 1.0683, p-value < 2.2e-16
alternative hypothesis: true autocorrelation is greater than 0
```

#### **Hình 49**

Trước khi phân tích số liệu, nhóm nghiên cứu làm rõ các khái niệm cần thiết như sau:

**Sai số độc lập (Independence of Errors):** Giả định này yêu cầu rằng phần dư của một quan sát không được phép ảnh hưởng hoặc có mối liên hệ với phần dư của quan

sát khác. Nếu vi phạm, các ước lượng về độ lệch chuẩn sẽ bị chệch, dẫn đến việc kiểm định ý nghĩa thống kê (p-value) không còn chính xác.

**Kiểm định Durbin-Watson (DW Test):** Là phương pháp phổ biến để phát hiện sự tự tương quan (autocorrelation) trong phần dư:

- Giá trị DW nằm trong khoảng từ 0 đến 4.
- $DW \sim 2$ : Không có sự tự tương quan (Lý tưởng).
- $DW < 2$  (tiến về 0): Tự tương quan dương.
- $DW > 2$  (tiến về 4): Tự tương quan âm.

Ngưỡng chấp nhận thông thường: Giá trị từ 1.5 đến 2.5 thường được coi là chấp nhận được.

#### Nhận xét:

- Để đánh giá tính độc lập của các sai số, kiểm định Durbin-Watson đã được thực hiện. Kết quả cho thấy hệ số  $DW = 1.0683$  với  $p\text{-value} < 2.2 \times 10^{-16}$ .
- Giá trị DW thấp hơn ngưỡng tiêu chuẩn (khoảng 1.5 - 2.5) chỉ ra sự tồn tại của hiện tượng tự tương quan dương giữa các phần dư. Điều này có nghĩa là giả định về sai số độc lập chưa được thỏa mãn hoàn toàn.
- Hiện tượng này có thể xuất phát từ bản chất của dữ liệu thu thập, cụ thể là yếu tố gia đình (thể hiện qua biến Family\_history). Các đối tượng khảo sát có thể có quan hệ huyết thống hoặc sống cùng một môi trường, dẫn đến việc các thói quen sinh hoạt và đặc điểm di truyền có sự tương đồng, làm cho các sai số không hoàn toàn ngẫu nhiên mà đi theo cụm (cluster).
- Mặc dù đây là một hạn chế của mô hình hồi quy Logistic tiêu chuẩn (vốn giả định các quan sát hoàn toàn độc lập), nhưng xét trong phạm vi nghiên cứu này, nhóm nghiên cứu chấp nhận kết quả hiện tại và ghi nhận đây là điểm cần cải thiện trong các nghiên cứu tương lai (ví dụ: sử dụng mô hình Mixed Effects Model để xử lý dữ liệu phân cấp).

#### Kiểm tra Giả định Tỷ lệ Chênh Tương xứng

- Mô hình Hồi quy Logistic Thứ bậc được xây dựng dựa trên một giả định cốt lõi gọi là Giả định Tỷ lệ Chênh Tương xứng (Proportional Odds Assumption), hay còn gọi là giả định hồi quy song song (Parallel Regression Assumption).
- Giả định này cho rằng tác động của các biến độc lập (beta) lên biến phụ thuộc là không đổi (hằng số) qua các ngưỡng phân loại khác nhau. Cụ thể trong nghiên cứu này, điều đó có nghĩa là tác động của một yếu tố (ví dụ: Age hoặc family\_history) lên xác suất chuyển từ nhóm "Normal" sang "Overweight" là hoàn toàn giống với tác động của nó lên việc chuyển từ nhóm "Overweight" sang "Obesity".
- Nếu giả định này bị vi phạm, các hệ số hồi quy duy nhất ước lượng được từ mô hình sẽ không phản ánh chính xác tác động thực tế của biến số tại các ngưỡng khác nhau, dẫn đến việc dự báo có thể bị sai lệch.



Để kiểm tra giả định này, ta sử dụng **Kiểm định Brant (Brant Test)**

```
1 brant_test_result <- brant(model2)
2 print(brant_test_result)
```

|                                   | X2           | df | probability  |
|-----------------------------------|--------------|----|--------------|
| Omnibus                           | 1.026098e+02 | 13 | 5.168675e-16 |
| Age                               | 3.104594e+01 | 1  | 2.519930e-08 |
| family_history_with_overweightyes | 8.477438e+00 | 1  | 3.595781e-03 |
| FAVCyes                           | 1.492428e+01 | 1  | 1.119133e-04 |
| FCVC                              | 1.781727e+01 | 1  | 2.431658e-05 |
| CAECOften                         | 8.648893e+00 | 1  | 3.272601e-03 |
| CAECSometimes                     | 6.299502e+00 | 1  | 1.207719e-02 |
| CH2O                              | 1.310803e+00 | 1  | 2.522493e-01 |
| FAF                               | 4.264332e-01 | 1  | 5.137443e-01 |
| TUE                               | 1.449787e-01 | 1  | 7.033809e-01 |
| CALCOften                         | 7.676290e+00 | 1  | 5.595107e-03 |
| CALCSometimes                     | 6.649059e-01 | 1  | 4.148333e-01 |
| MTRANSOther                       | 1.313552e-01 | 1  | 7.170310e-01 |
| MTRANSPublic_Transportation       | 6.184096e-03 | 1  | 9.373197e-01 |

Hình 50

*Đặt giả thuyết kiểm định:*

- $$\begin{cases} H_0 : \text{Giả định Tỷ lệ Chênh Tương xứng được thỏa mãn (Các hệ số } \beta \text{ là đồng nhất qua các ngưỡng)} \\ H_1 : \text{Giả định Tỷ lệ Chênh Tương xứng bị vi phạm.} \end{cases}$$

**Nhận xét:**

- Với Kiểm định Tổng thể (Omnibus), ta thấy giá trị thống kê Chi-bình phương ( $X^2$ ) là 102.61 với giá trị p-value =  $5.17 \times 10^{-16}$  (nhỏ hơn rất nhiều so với mức ý nghĩa 0.05), nên ta có đủ cơ sở bác bỏ  $H_0$ . Ta có thể kết luận mô hình về tổng thể đã vi phạm nghiêm trọng giả định Tỷ lệ Chênh Tương xứng.
- Khi xem xét chi tiết từng biến, ta nhận thấy sự vi phạm giả định này đến từ các biến quan trọng sau (có p-value < 0.05). Với biến Age ( $p \approx 2.52 \times 10^{-8}$ ) cho thấy Tác động của tuổi tác lên việc chuyển từ "Bình thường" sang "Thừa cân" khác biệt so với tác động lên việc chuyển từ "Thừa cân" sang "Béo phì". Với biến family\_history ( $p \approx 0.0036$ ) cho thấy Yếu tố di truyền có mức độ ảnh hưởng không đồng đều giữa các giai đoạn tăng cân. Với biến FAVC ( $p \approx 0.0001$ ) và biến FCVC ( $p \approx 0.00002$ ) cho thấy Thói quen ăn uống (calo cao và rau xanh) cũng tác động khác nhau tùy thuộc vào mức độ béo phì hiện tại. CAEC và CALCOften cũng cho thấy sự vi phạm giả định. Ngược lại, các biến như CH2O, FAF, TUE, và MTRANS có p-value > 0.05, cho thấy các biến này thỏa mãn giả định và tác động của chúng là ổn định qua các ngưỡng.
- Việc vi phạm giả định Proportional Odds cho thấy mối quan hệ giữa các biến độc lập và tình trạng béo phì phức tạp hơn mô hình tuyến tính đơn giản. Mặc dù mô hình Hồi quy Logistic Thứ bậc vẫn cung cấp cái nhìn tổng quan về chiều hướng tác động (tăng/giảm nguy cơ), nhưng các hệ số ước lượng có thể chưa phản ánh chính xác độ lớn tác động tại từng ngưỡng chuyển đổi cụ thể. Đây là một hạn chế cần lưu ý của nghiên cứu, và có thể giải thích lý do tại sao mô hình gặp khó khăn trong việc phân loại chính xác nhóm "Overweight" (như đã thấy ở Ma trận nhầm lẫn).



## VI Thảo luận và mở rộng

### 1 Thảo luận

Qua bài báo cáo, nhóm đã xây dựng mô hình Hồi quy Logistic Thứ bậc (Ordinal Logistic Regression) nhằm dự đoán mức độ béo phì của các cá nhân (Normal – Overweight – Obesity) dựa trên thói quen ăn uống và tình trạng thể chất. Mô hình được huấn luyện trên tập dữ liệu 70% và đánh giá bằng 30% dữ liệu còn lại.

Kết quả mô hình cho thấy có ba biến đáng chú ý:

- Age (tuổi) và Family history of overweight (tiền sử gia đình) là hai yếu tố ảnh hưởng rõ rệt đến nguy cơ béo phì. Khi tuổi tăng hoặc cá nhân có người thân bị thừa cân/béo phì, khả năng rơi vào nhóm cân nặng cao hơn tăng đáng kể.
- FAF (mức độ hoạt động thể chất) là một biến thể hiện tác động bảo vệ rõ ràng và có mức ảnh hưởng đáng chú ý trong mô hình. Khi mức độ vận động tăng lên, khả năng rơi vào các nhóm cân nặng cao hơn giảm xuống, cho thấy yếu tố luyện tập không chỉ mang tính hỗ trợ mà còn có vai trò thực sự quan trọng trong việc duy trì cân nặng ổn định và phòng ngừa thừa cân, béo phì trong thực tế.

Mô hình Hồi quy Logistic thứ bậc giúp dự đoán nguy cơ béo phì và cho phép nhìn thấy mức độ ảnh hưởng của các yếu tố khác nhau. Phương pháp này linh hoạt, không yêu cầu nhiều giả định nghiêm ngặt, đồng thời hỗ trợ đưa ra những nhận xét có giá trị từ dữ liệu quan sát.

Mặc dù mô hình cho kết quả tương đối tốt và phản ánh hợp lý vai trò của các yếu tố quan trọng, song vẫn tồn tại một số hạn chế nhất định. Mô hình chưa khai thác đầy đủ các mối quan hệ phức tạp giữa các biến và còn gặp khó khăn trong việc phân biệt rõ ràng giữa các mức độ trung gian. Bên cạnh đó, hiệu quả của mô hình chịu ảnh hưởng đáng kể bởi cách lựa chọn biến và chất lượng dữ liệu đầu vào. Việc cân nhắc mở rộng dữ liệu, tinh chỉnh tập biến và xem xét các cách tiếp cận phân tích khác có thể giúp cải thiện thêm độ tin cậy và tính ổn định của kết quả.

### 2 Mở rộng

Random Forest (Rừng ngẫu nhiên) là một mô hình học máy thuộc nhóm ensemble learning (phương pháp học tổ hợp, kết hợp nhiều mô hình đơn lẻ để tạo thành một mô hình mạnh hơn), được xây dựng bằng cách kết hợp nhiều cây quyết định nhằm nâng cao độ chính xác và khả năng khái quát hóa của mô hình. Mô hình này có thể xem như một sự mở rộng linh hoạt hơn so với Hồi quy Logistic Thứ bậc (Ordinal Logistic Regression) trong việc xử lý các bài toán phân loại, đặc biệt khi mối quan hệ giữa các biến không còn tuyến tính và dữ liệu có cấu trúc phức tạp hơn.

Trước tiên, cần phải tiến hành tải package “randomForest” và xây dựng mô hình Random Forest bằng tập train data. Kết hợp với việc thực hiện hàm importance() để tính toán tầm quan trọng của các biến từ mô hình Random Forest.

```
1 #Xây dựng mô hình Random Forest
2 install.packages("randomForest")
3 library(randomForest)
```

```

4 model_RandomForest <- randomForest(
5   NObeyesdad_group ~ Gender + Age + family_history_with_
      overweight +
6     FAVC + FCVC + NCP + CAEC + SMOKE + CH2O + SCC +
7     FAF + TUE + CALC + MTRANS,
8   data = train_data,
9   ntree = 300,
10  importance = TRUE
11 )
12 #Bảng độ quan trọng của từng biến
13 importance_df <- importance(model_RandomForest)
14 print(importance_df)

```

|                                | Normal    | Overweight | Obesity   | MeanDecreaseAccuracy | MeanDecreaseGini |
|--------------------------------|-----------|------------|-----------|----------------------|------------------|
| Gender                         | 12.752977 | 17.655245  | 25.869740 | 31.154792            | 28.85702         |
| Age                            | 32.408311 | 34.403681  | 37.617046 | 46.361502            | 143.81047        |
| family_history_with_overweight | 36.081807 | 19.236715  | 51.025938 | 52.541355            | 88.36010         |
| FAVC                           | 8.782003  | 19.337867  | 25.138068 | 27.922140            | 28.26367         |
| FCVC                           | 10.173610 | 25.363023  | 36.826115 | 39.153637            | 78.14213         |
| NCP                            | 18.223458 | 27.251752  | 36.446417 | 39.412129            | 91.57586         |
| CAEC                           | 36.604250 | 25.001843  | 38.740332 | 47.928634            | 90.14314         |
| SMOKE                          | -1.146661 | 3.246471   | 6.825595  | 5.298392             | 4.61265          |
| CH2O                           | 14.967020 | 20.302022  | 26.868894 | 29.409922            | 78.88980         |
| SCC                            | 1.422570  | 17.147473  | 8.881793  | 16.299312            | 11.47646         |
| FAF                            | 17.279219 | 22.297539  | 33.328828 | 36.800158            | 87.11403         |
| TUE                            | 20.031191 | 21.749116  | 29.250585 | 33.670737            | 78.34778         |
| CALC                           | 12.221179 | 18.626375  | 22.767091 | 26.415433            | 39.99383         |
| MTRANS                         | 14.042467 | 21.209416  | 23.151237 | 29.437461            | 35.63654         |

**Hình 51:** Kết quả phân tích tầm quan trọng của các biến trong mô hình Random Forest

Tiếp theo, tạo ma trận nhầm lẫn tính toán độ chính xác (Accuracy), độ nhạy (Sensitivity), và độ đặc hiệu (Specificity).

```

1 prediction_RandomForest <- predict(model_RandomForest, newdata
   = test_data)
2 confusionMatrix_RandomForest <- confusionMatrix(
3   factor(prediction_RandomForest, levels = levels(test_data$
      NObeyesdad_group)),
4   test_data$NObeyesdad_group
5 )
6 print(confusionMatrix_RandomForest)

```

#### Confusion Matrix and Statistics

| Prediction | Reference |            |         |
|------------|-----------|------------|---------|
|            | Normal    | Overweight | Obesity |
| Normal     | 154       | 26         | 13      |
| Overweight | 8         | 122        | 15      |
| Obesity    | 5         | 26         | 263     |

#### Overall Statistics

Accuracy : 0.8528  
95% CI : (0.8228, 0.8796)  
No Information Rate : 0.4604  
P-Value [Acc > NIR] : < 2.2e-16

Kappa : 0.7708

McNemar's Test P-Value : 0.001115

#### Statistics by Class:

|                      | Class: Normal | Class: Overweight | Class: Obesity |
|----------------------|---------------|-------------------|----------------|
| Sensitivity          | 0.9222        | 0.7011            | 0.9038         |
| Specificity          | 0.9161        | 0.9498            | 0.9091         |
| Pos Pred Value       | 0.7979        | 0.8414            | 0.8946         |
| Neg Pred Value       | 0.9704        | 0.8932            | 0.9172         |
| Prevalence           | 0.2642        | 0.2753            | 0.4604         |
| Detection Rate       | 0.2437        | 0.1930            | 0.4161         |
| Detection Prevalence | 0.3054        | 0.2294            | 0.4652         |
| Balanced Accuracy    | 0.9191        | 0.8255            | 0.9064         |

**Hình 52:** Kết quả thông số ma trận nhầm lẫn, độ chính xác của mô hình Random Forest.

Dựa trên kết quả mô hình Random Forest, hệ số chính xác (Accuracy) của mô hình đạt mức 85.28% (với khoảng tin cậy 95%:[0.8228,0.8796]). Điều này cho thấy mô hình có khả năng phân loại đúng các đối tượng với tỷ lệ 85.28%, cao hơn đáng kể so với mô hình Hồi quy Logistic Thứ bậc đã được xây dựng trước đó (là 64.08%). Do đó, có thể kết luận rằng mô hình Random Forest đã đạt được sự cải thiện vượt trội so với hồi quy logistic thứ bậc trong việc dự đoán mức độ béo phì. Với mức độ chính xác này và chỉ số Kappa 0.7708 (mức đồng thuận tốt), mô hình được xem là đáng tin cậy và có thể áp dụng hiệu quả trong các tình huống dự báo thực tiễn. Cần xem xét các yếu tố khác như chất lượng dữ liệu, cách xử lý dữ liệu hoặc thử nghiệm các mô hình khác để nâng cao hiệu quả phân loại.